ROLL

like a Reinforcement Learning
Algorithm Developer

ROLL: Reinforcement Learning Optimization for Large-scale Learning

——高效且用户友好的大模型RL训练框架

目录

Part 1：ROLL诞生篇

Part 2：ROLL核心设计篇

Part 3：ROLL实践篇

Part 1：ROLL诞生篇

LLM与RL：痛点与ROLL的诞生

- 我们设计框架时，该考虑什么问题?
  - 早期的强化学习框架多是为了满足特定研究需求而设计，随着应用场景的不断扩展，框架通过不断叠加功能来满足新需求，这种渐进式演变导致架构变得臃肿，维护成本越来越高。
  - 不同用户群体对框架的期望存在显著差异，框架设计需要在这些诉求之间找到平衡点：通过合理的抽象层次和模块化设计，让不同用户都能高效地使用框架，在保持核心简洁的同时，提供足够的扩展性支持多样化需求。

- *Rich Training Recipes*
- *Superior Performance*
- *Easy Device-Reward Mapping*
- *...*

Product Developer

- *Constrained Device Execution*
- *Pluggable Reasoning Pipeline*
- *...*

Algorithm Researcher

- *Fast and Effective*
- *Scalability and Fault Tolerance*
- *...*

Tech Pioneer

LLM与RL：痛点与ROLL的诞生

- 同时满足这三类用户是一个“不可能三角”吗?
  - 用户角色往往是动态转换的：
    - 业务算法工程师可能需要进行创新研究来解决特定问题；
    - 学术研究员在推进前沿研究的同时可能要考虑工程落地；
    - 而工业界研究员则经常在基础研究和实际应用间切换。
  - 这种角色的流动性要求框架能够无缝支持不同场景下的需求转换。

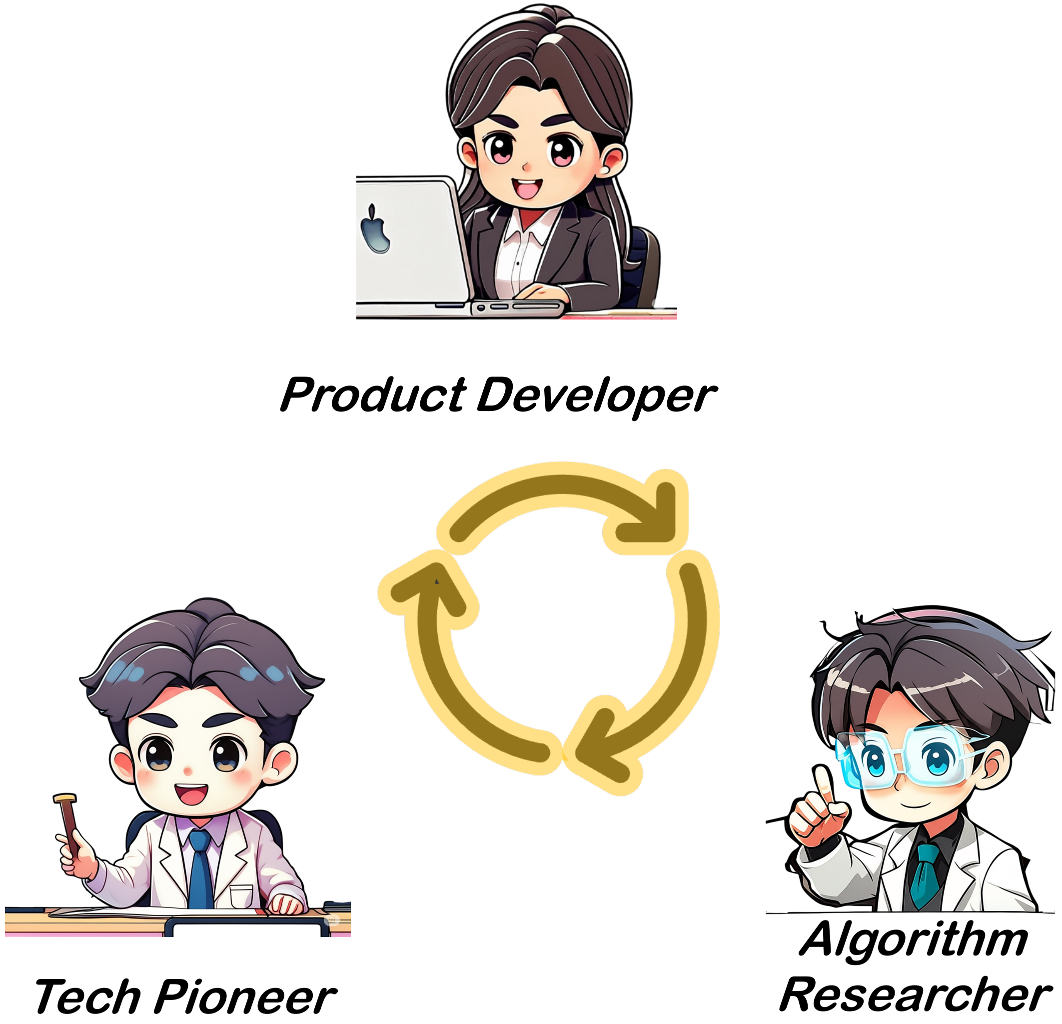

LLM与RL：痛点与ROLL的诞生

- 在设计框架时，我们的理念是将所有类型的用户都视为“一等公民”，而不是过分偏向某一群体。这意味着框架需要在不同层次上同时满足多种需求：
  - 为业务工程师提供清晰的抽象和便捷的部署能力，
  - 为学术研究员保留足够的灵活性和可定制性
  - 为工业界研究员在研究创新和规模化应用之间搭建桥梁。

ROLL
like a Reinforcement Learning Algorithm Developer

- 通过精心的接口设计和架构规划，我们致力于在易用性和效率之间找到平衡点，让用户能够根据实际需求无障碍地在不同使用模式间切换，真正实现框架对所有用户的普遍友好。

ROLL框架概览：关键特性

- 核心定位: 高效、用户友好的强化学习库，专为LLM大规模优化设计
- 关键特性:
  - **多任务强化学习**：内置丰富的 RL 任务支持，涵盖数学、代码、通用推理、开放式问答、指令遵循等，一套训练循环即可多领域联合优化，采样率与数据权重可灵活动态调整
  - **智能体强化学习（Agentic RL）**：原生支持多环境、多角色智能体 – 环境交互（游戏、多轮对话等），并具有灵活的并行化和内置管理功能，可满足多种任务需求
  - **算法友好**：提供灵活且丰富的 RL 策略配置，开箱即用地支持 PPO、GRPO、Reinforce++ 等算法

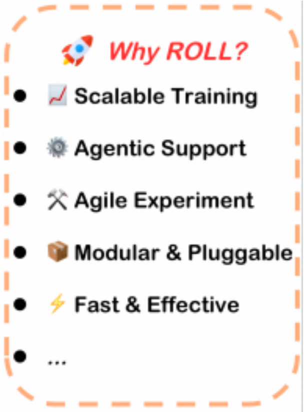

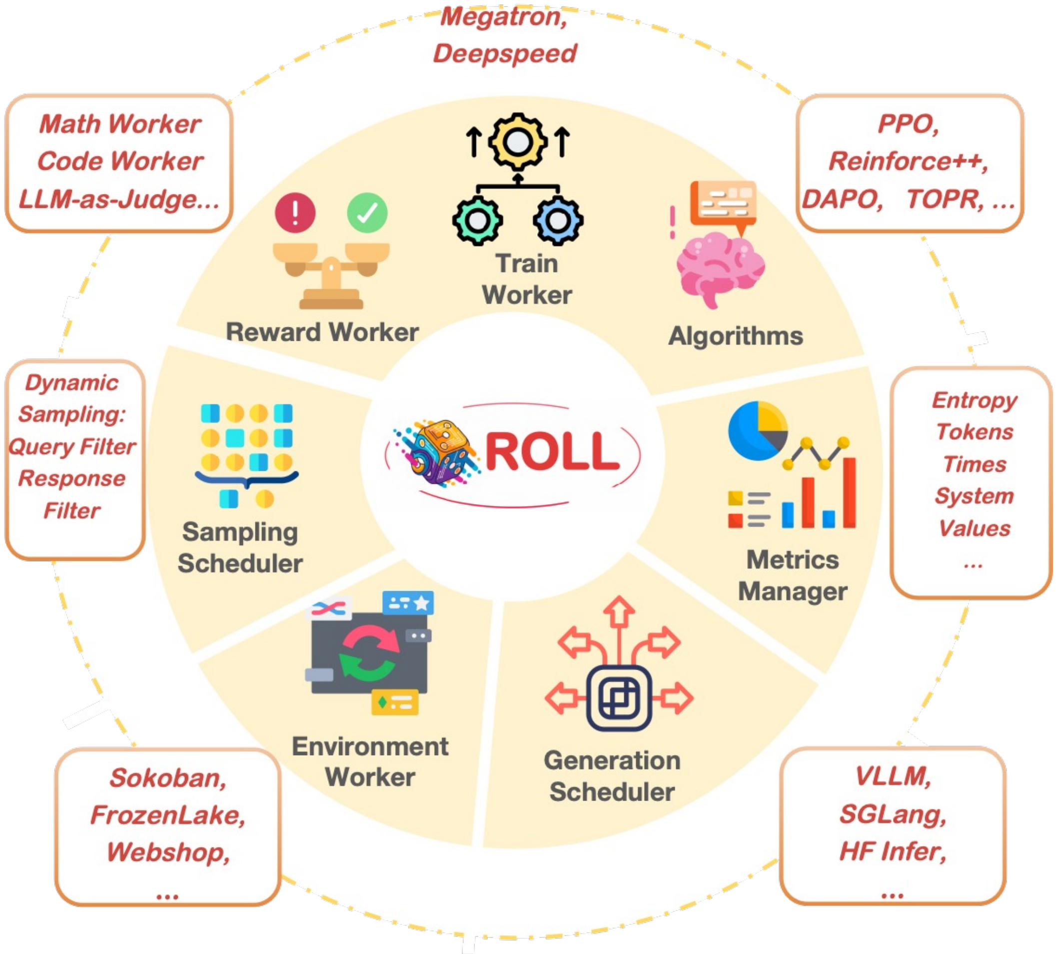

ROLL框架概览：关键特性

- 核心定位: 高效、用户友好的强化学习库，专为LLM大规模优化设计
- 关键特性:
  - **丰富的训推引擎**：基于 Ray 的多角色分布式架构，灵活支持 vLLM、SGLang、Megatron-Core、DeepSpeed 等主流推理 / 训练引擎，从单机到千卡集群均能轻松运行
  - **极致易用与模块化扩展**：Rollout Scheduler、AutoDeviceMapping 等关键模块极大简化 pipeline 开发和调试，支持按需组合套件，后端推理 / 训练引擎自由切换。
  - **样本级调度与动态采样**：样本级 Rollout 生命周期调度机制，支持异步奖励计算、动态采样、按样本裁剪与 EarlyStopping，显著提升训练效率与资源利用率。
  - **可观察性**：集成了swanlab / wandb / tensorboard，支持实时跟踪每个领域、每个策略、每个奖励的性能 —— 从高层概况到细粒度分析

🚀 *Why ROLL?*

- 📈 Scalable Training
- ⚙️ Agentic Support
- ⚒ Agile Experiment
- 📦 Modular & Pluggable
- ⚡ Fast & Effective
- ...

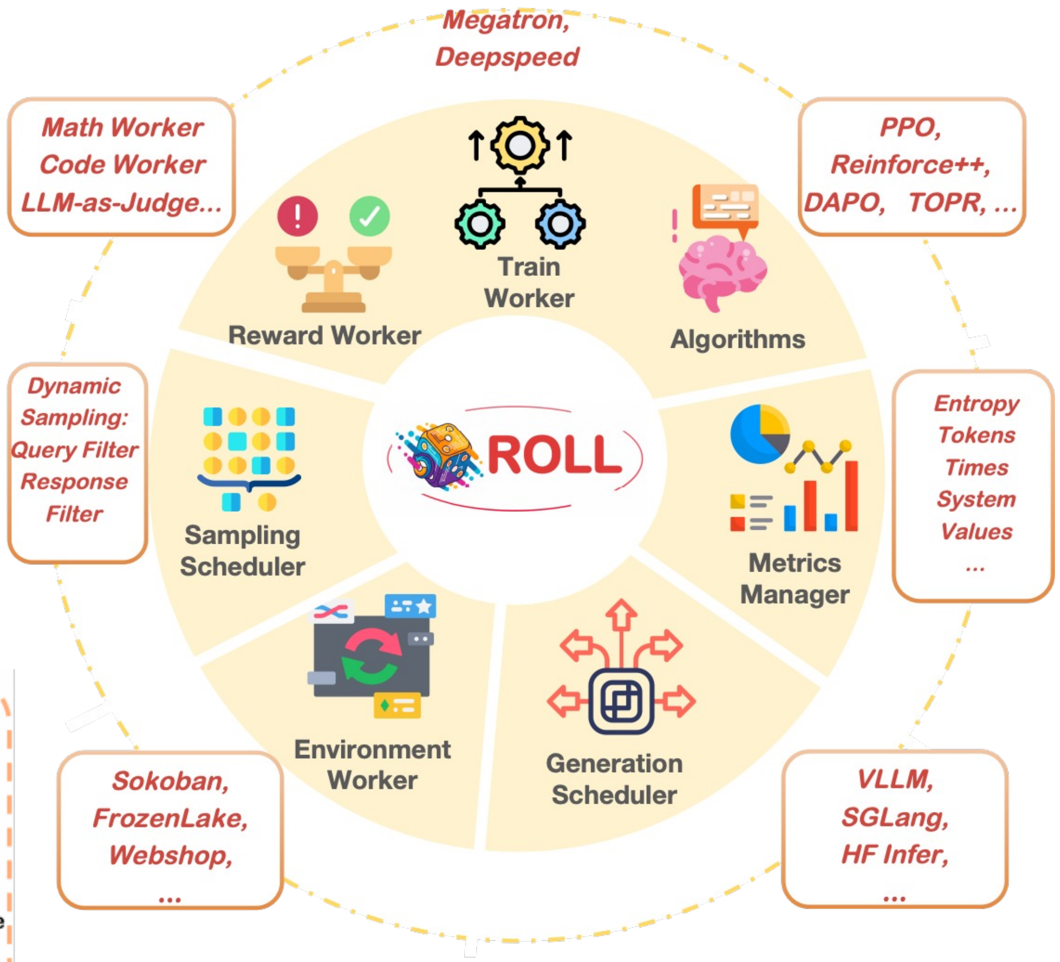

ROLL
like a Reinforcement Learning Algorithm Developer

训练效果展示：RLVR (RL with Verifiable Reward)

- RLVR是什么？ 优化LLM在有可验证答案任务上的性能（数学、代码、通用推理）
- 实验设置:
  - 数据集：DeepMath、KodCode等，多领域混合训练
  - 模型：Qwen2.5-7B-Base, Qwen3-30B-A3B-Base
  - 算法：PPO Loss + REINFORCE，多验证机制（规则、沙箱、LLM-as-Judge）
- 核心结果 (图3a, 4a):
  - Qwen2.5-7B-Base: 整体准确率从 0.18 提升至 0.52。数学：0.20->0.53；代码：0.13->0.41
  - Qwen3-30B-A3B-Base: 整体准确率从 0.27 提升至 0.62
- 稳定性与鲁棒性: 多任务混合训练中模型持续提升，未出现崩溃
- 多模态支持: Qwen2.5-VL-7B-Instruct在GEOQA_R1V_Train_8K上表现良好 (图4c)。

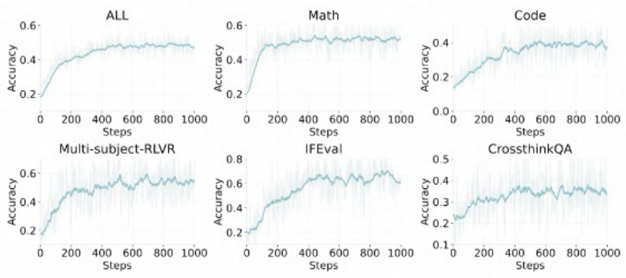

Figure 3: Accuracy Trends Across Different Tasks on Qwen2.5-7B-Base.

Figure3 a. Dense: Qwen2.5-7B-Base

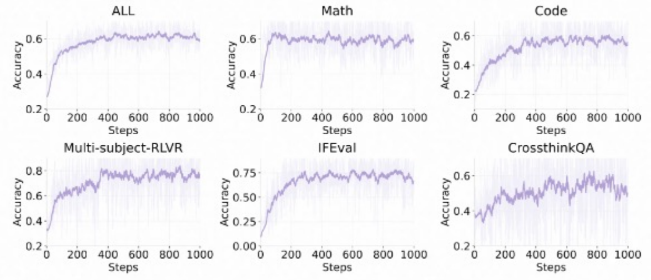

Figure 4: Accuracy Trends Across Different Tasks on Qwen3-30B-A3B-Base.

Figure 4 a. MOE: Qwen3-30B-A3B-Base

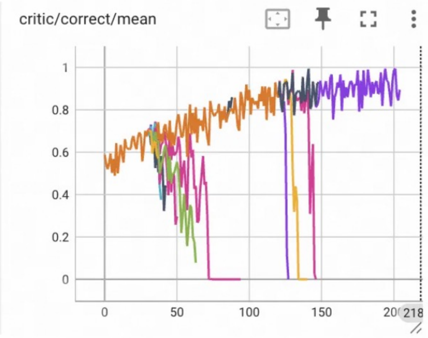

Figure 3b.MOE 200+B
Crash and resume

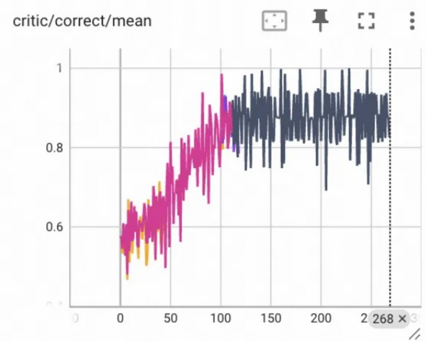

Figure 4b.MOE 200+B
Stable training

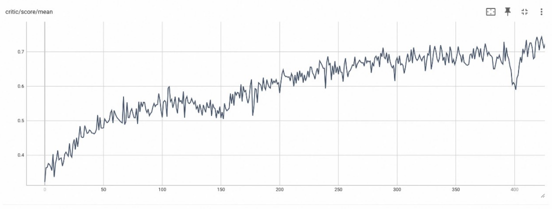

Figure 4 c Qwen2.5-VL-7B-Instruct 训练score曲线

ROLL
like a Reinforcement Learning Algorithm Developer

训练效果展示：Agentic RL

- Agentic RL是什么？ 训练LLM作为智能体，在多轮交互环境中完成复杂任务。
- 实验环境:
  - Sokoban (推箱子): 成功率从16.8%提升至26.0% (训练)，有效动作比例提升至73.4%
  - FrozenLake (冰湖): 成功率从16.8%提升至26.0% (训练)，有效动作比例提升至88.8%
  - WebShop (在线购物): 复杂自然语言交互，任务成功率从37%大幅提升至85%+，平均操作数从7次降至4次
- 核心优势:
  - 显著提升任务成功率与执行效率
  - 展现出良好的泛化能力和跨环境迁移能力
  - 可扩展的Agent-Env**异步并行**多轮交互采样，更高效
  - **异步训练**：rollout/训练解耦，扩展性高

Sokoban

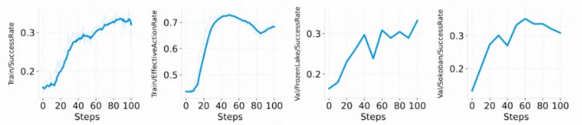

Figure 5: Performance metrics for the SimpleSokoban environment training. *SuccessRate* denotes the success rate of reaching the goal. *EffectiveActionRate* represents the proportion of valid actions executed.

FrozenLake

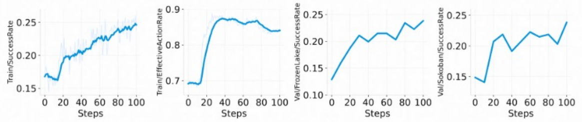

Figure 6: Performance metrics for the FrozenLake environment training.

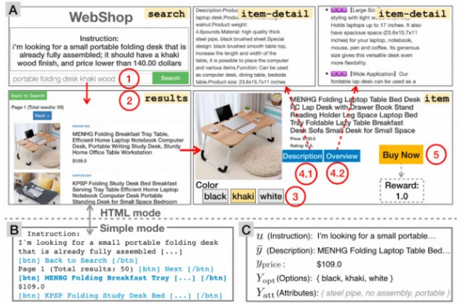

WebShop

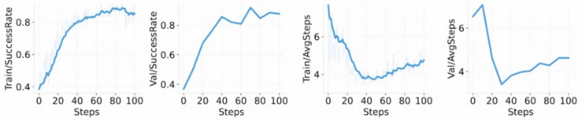

Figure 7: Performance metrics for the WebShop environment training. *AvgSteps* indicates the average number of steps required to complete the task, where fewer steps imply higher action efficiency.

Part 2：ROLL核心设计篇

ROLL

like a Reinforcement Learning Algorithm Developer

算法抽象：算法视角的模块化与灵活性

Workflow Overview

- 运行时设置 (Runtime Setup)
  - 根据用户配置，自动分配资源，创建各分布式组件
- 训练迭代 (Training Iteration):
  - 数据生成 (Generation)

    并行交互： Actor、Env或Reward worker**异步并行**协作，高效生成经验数据并计算奖励、过滤
  - 推理 (Infer)

    对数据的前向推理，构造完整训练样本
  - 训练 (Train)

    模型更新： Actor和Critic更新参数，将参数同步回生成模型，实现策略的持续迭代与优化

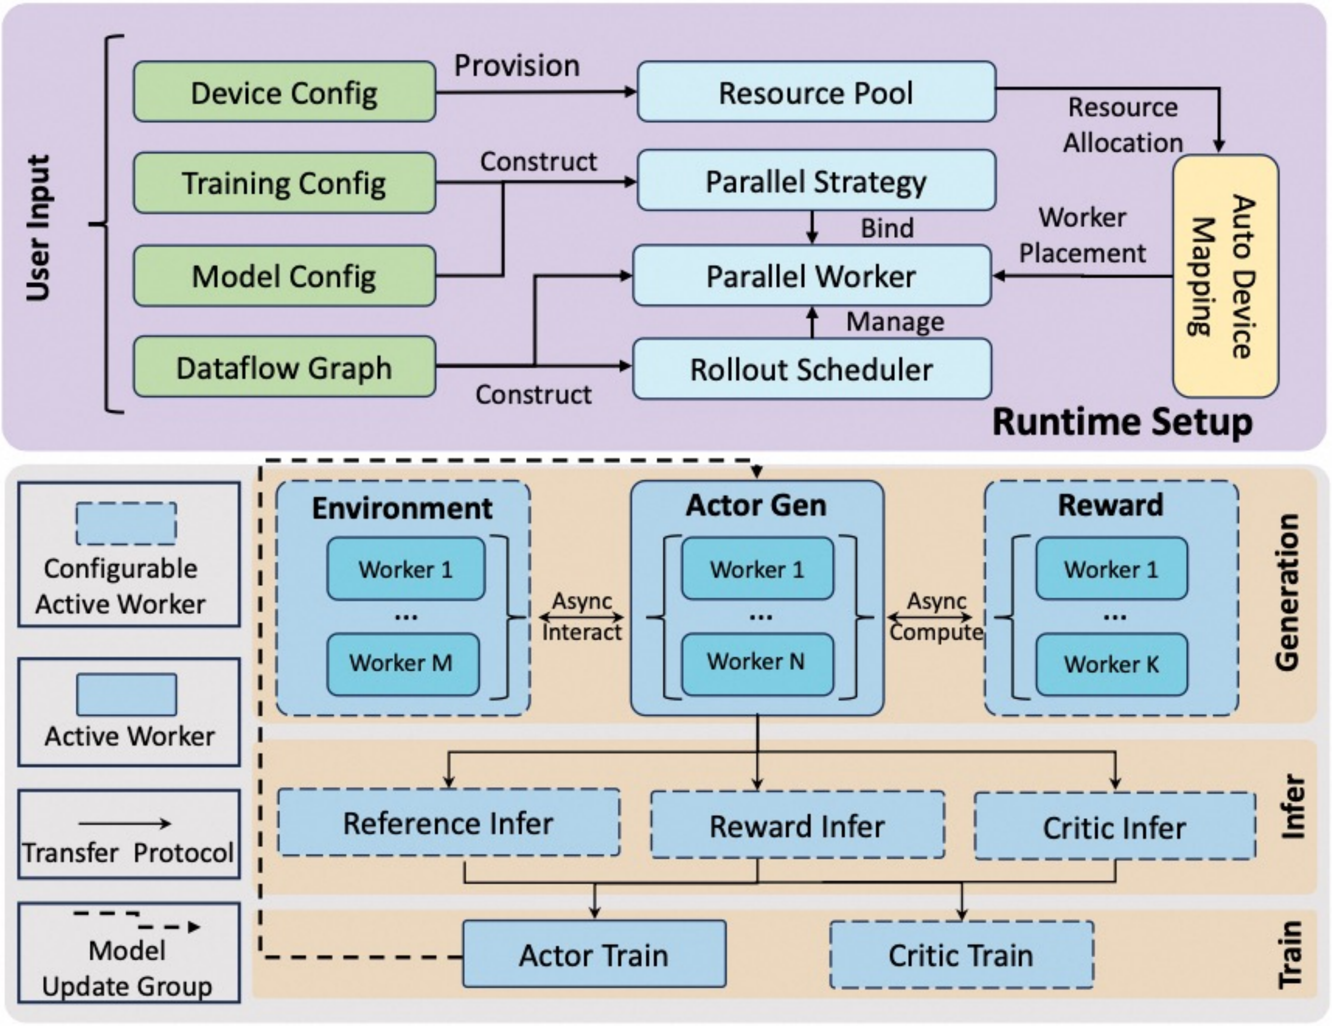

(b) Workflow

算法抽象：算法视角的模块化与灵活性

解耦算法逻辑与分布式工程实现

➢ Single Controller Pipeline:

- 单进程视角编排各角色的计算流程
- 简化调度，提高开发效率

➢ Worker抽象: 可插拔的模块化组件

- Actor Worker: 模型生成与策略训练
- Critic Worker (可选): 状态价值估计
- Reward Worker: 多种奖励计算（规则验证、代码沙箱、LLM as Judge）
- Environment Worker:管理与环境的多轮交互

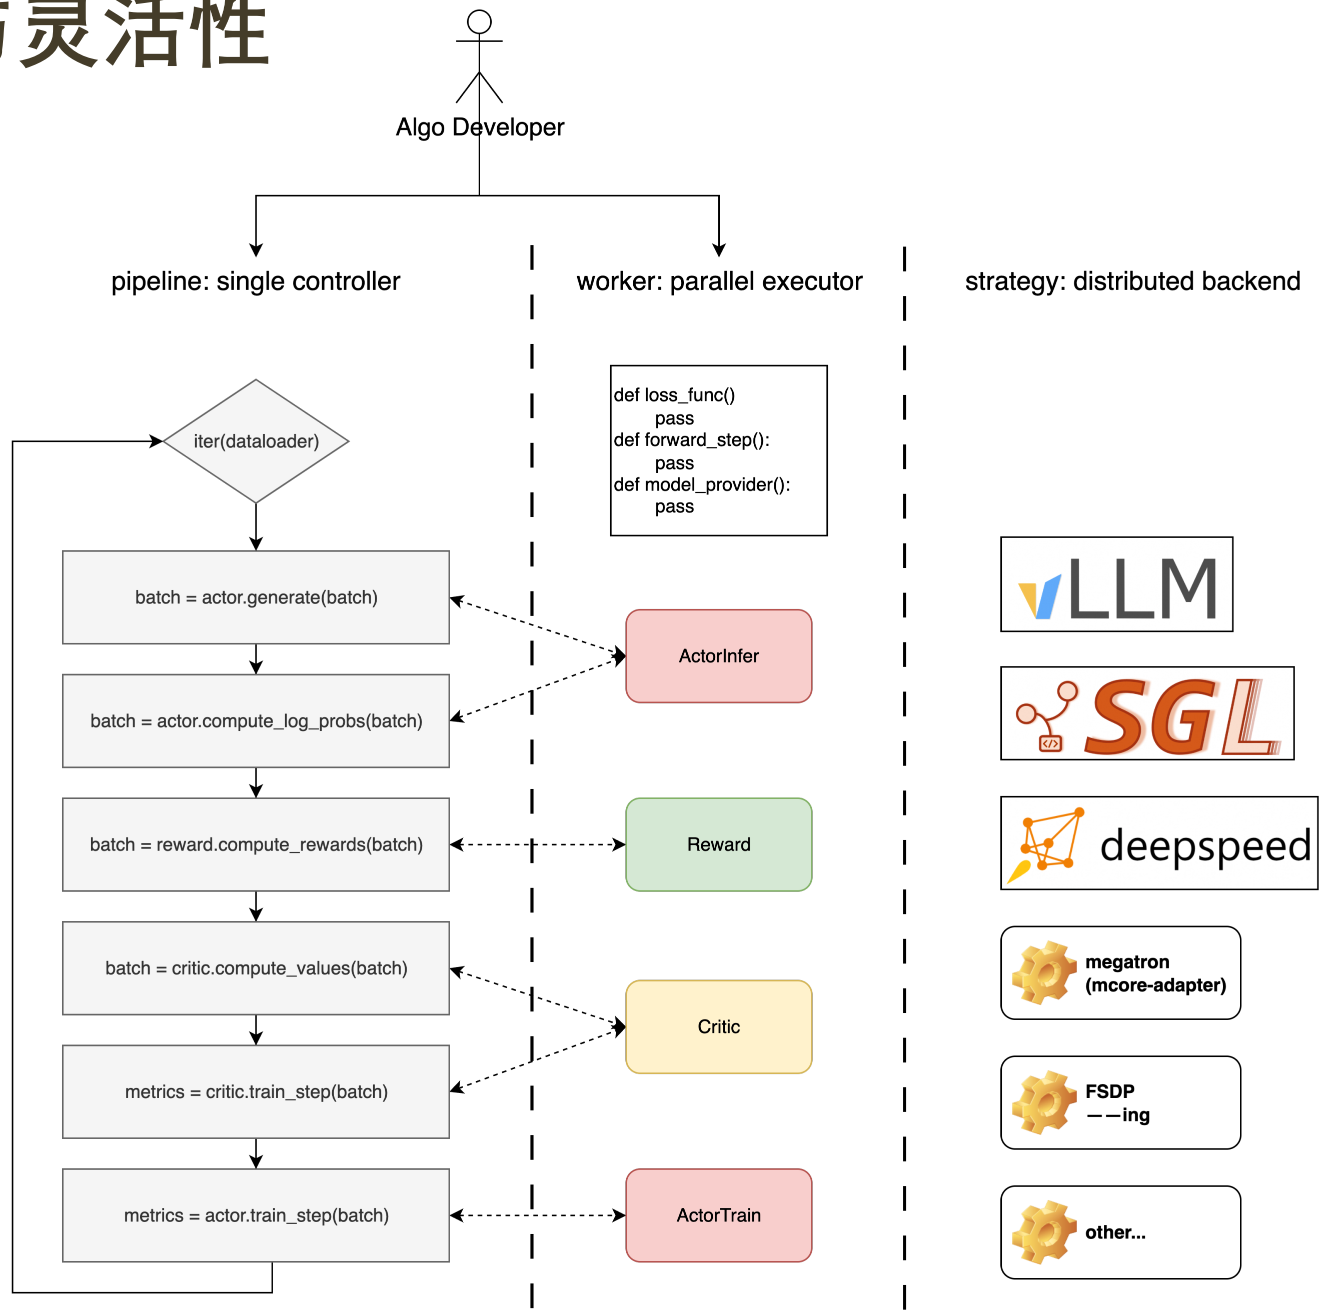

框架架构：面向分布式与高性能的LLM执行体系

模块化与可扩展的分布式架构

核心理念：构架面向LLM的分布式计算基石

- **高度模块化与可扩展性**：ROLL在算法抽象之上，构建了一套灵活高效的分布式执行架构，无缝集成多种先进LLM推理与训练引擎
- **广泛适用场景**：从单机部署到大规模GPU集群，ROLL均能提供卓越的性能支持，确保了其在多样化应用场景中的适应性与扩展性
- **引擎无缝切换**：支持训练(DeepSpeed、Megatron、FSDP[ing])、推理(vLLM、SGLang)的无缝切换，并扩展了高效的GPU offload/reload实现，充分发挥并行计算优势

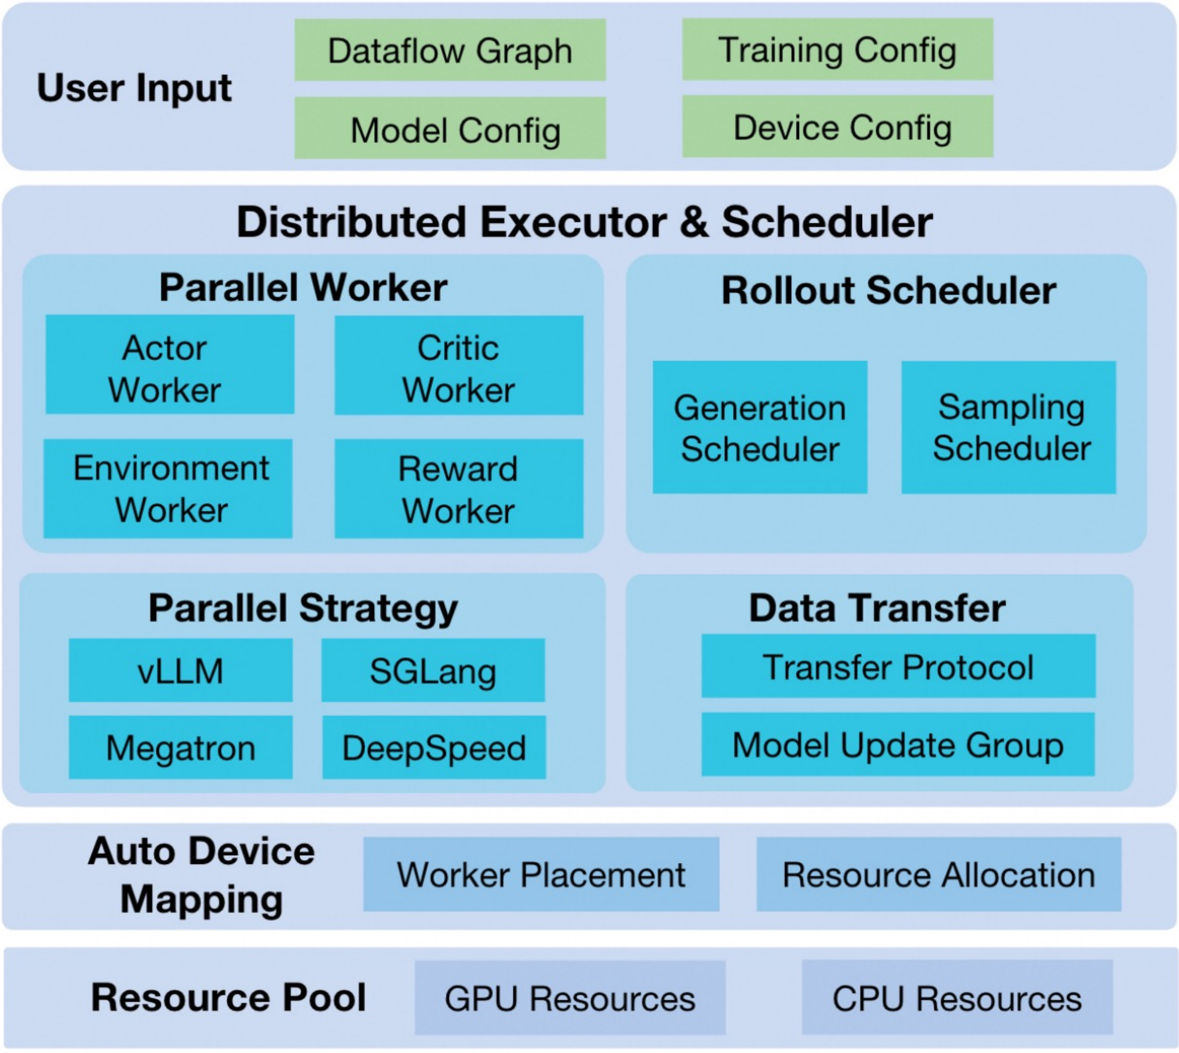

(a) Architecture

框架架构：面向分布式与高性能的LLM执行体系

模块化与可扩展的分布式架构

关键执行单元：Parallel Worker

- ➢ 资源持有单元
  - ROLL中的基本资源管理单位，每个Parallel Worker持有一组Ray PlacementGroup资源
  - 用户在Worker内自定义业务逻辑，单进程视角编程、分布式执行
- ➢ Cluster协同管理
  - 通过Cluster层对各角色（如Actor、Critic、Environment、Reward）的Workers进行统一管理
  - Pipeline里描述各角色Cluster协同计算过程，Worker执行具体分布式计算

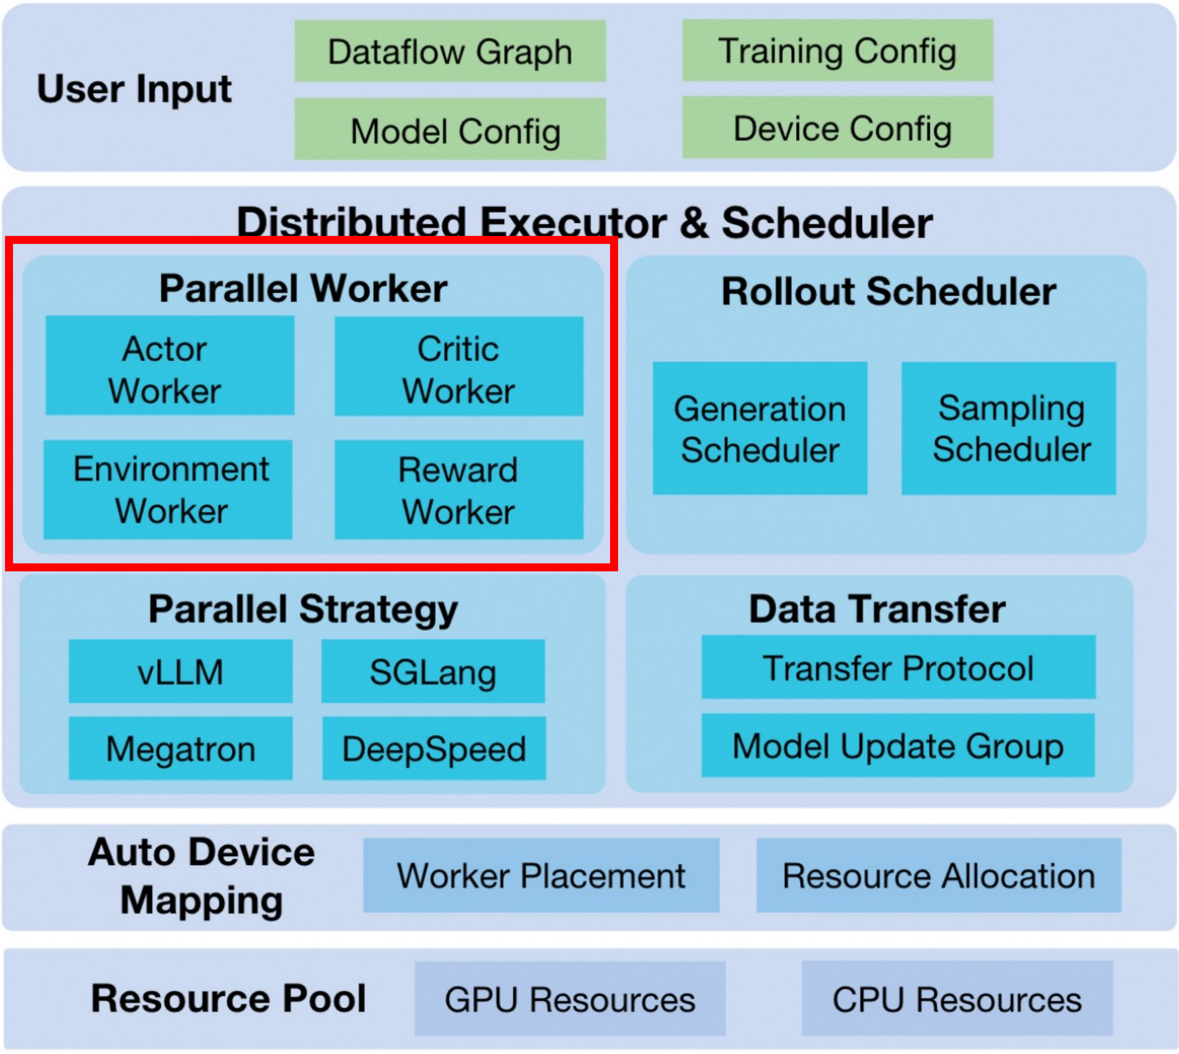

(a) Architecture

框架架构：面向分布式与高性能的LLM执行体系

模块化与可扩展的分布式架构

核心引擎集成：Parallel Strategy

- 训练: 无缝集成MegatronCore和DeepSpeed，支持5D并行（DP, PP, TP, CP, EP），结合ZeRO/Offload降低显存
- 推理: 整合vLLM和SGLang，支持TP/EP/PP

```python
class TrainStrategy(InferenceStrategy):
    def __init__(self, worker: "Worker"):...

    def setup_collective_group(self, model_update_name, comm_plan, backend="nccl"):...

    def train_step(
        self,
        batch: DataProto,
        loss_func: Callable[[DataProto, torch.Tensor], Tuple[torch.Tensor, Dict[str, torch.Tensor]]],
    ):...

    def model_update(self, *args, **kwargs):...

    def save_checkpoint(self, *args, **kwargs):...

    def load_checkpoint(self, *args, **kwargs):
        pass
```

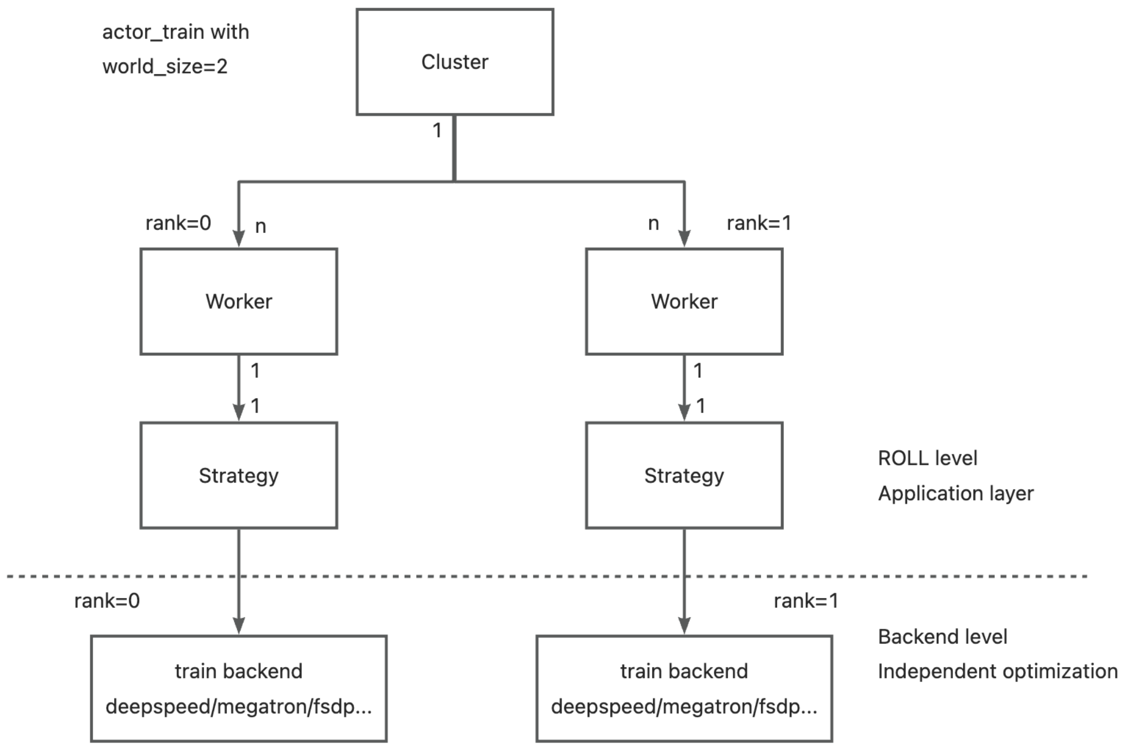

框架架构：面向分布式与高性能的LLM执行体系

模块化与可扩展的分布式架构

核心引擎集成：Parallel Strategy

- 训练: 无缝集成MegatronCore和DeepSpeed，支持5D并行（DP, PP, TP, CP, EP），结合ZeRO/Offload降低显存
- 推理: 整合vLLM和SGLang，支持TP/EP/PP

```python
class InferenceStrategy(ABC):  xiongshaopan.xsp +2 *
    strategy_name = None

    def __init__(self, worker: "Worker"):...

    def initialize(self, *args, **kwargs):  xiongshaopan.xsp
        raise NotImplementedError
    def forward_step(  5 usages  xiongshaopan.xsp +1
        self,
        batch: DataProto,
        forward_func: Callable[[DataProto, torch.Tensor], Tuple[torch.Tensor, Dict[str, torch.Tensor]]],
    ) -> Dict[str, torch.Tensor]:...
    def generate(self, *args, **kwargs):...
    def add_request(self, command, data: DataProto, *args, **kwargs):...

    # 参数同步相关接口
    def broadcast_bucket(self, model_update_name, src_pp_rank, meta_infos, bucket_size):...
    def setup_collective_group(self, model_update_name, comm_plan, backend="nccl"):...

    # offload/load 相关接口
    def load_states(self):...
    def offload_states(self, *args, **kwargs):  xiongshaopan.xsp
        raise NotImplementedError
```

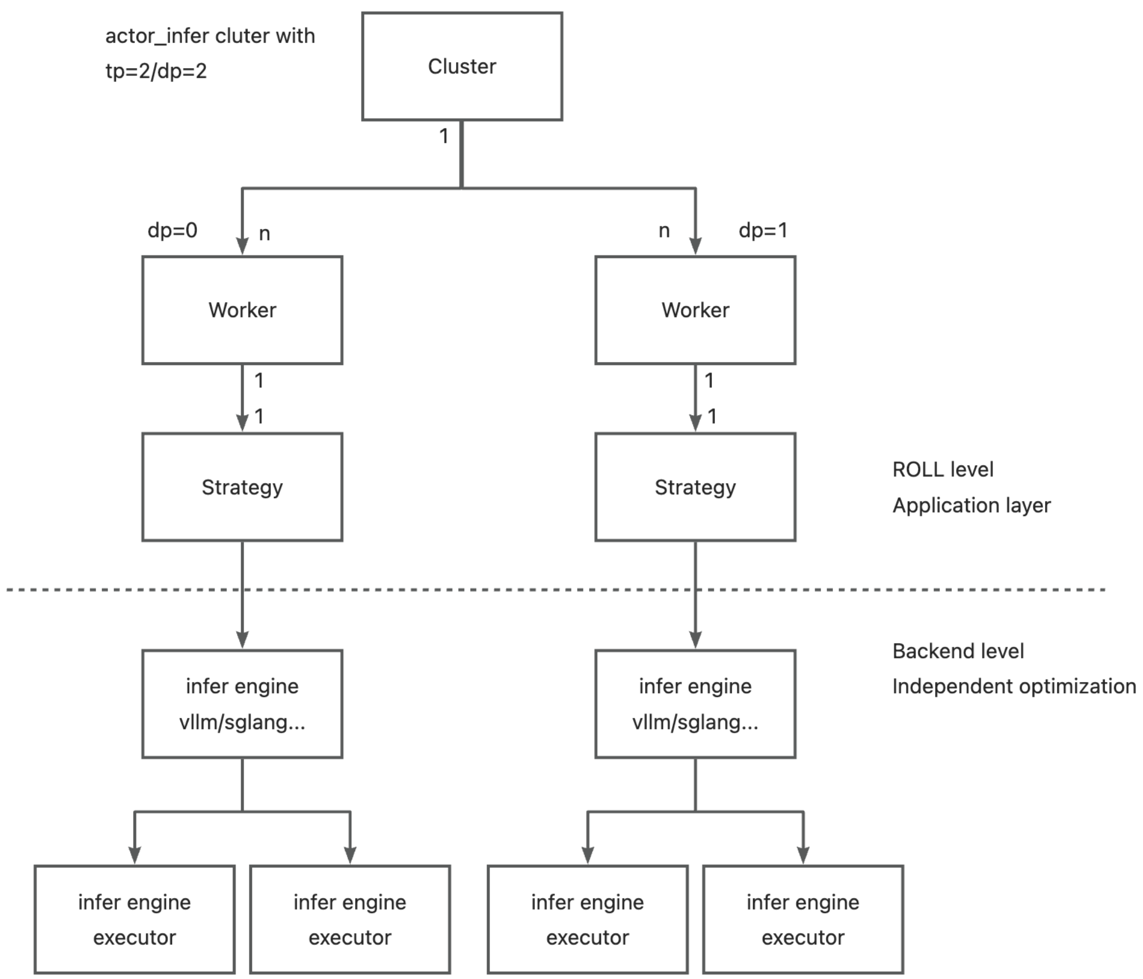

框架架构：面向分布式与高性能的LLM执行体系

模块化与可扩展的分布式架构

- **Rollout Scheduler:** 样本级异步并行rollout，动态负载均衡、异步执行、灵活任务路由
- **Data Transfer:** ModelUpdateGroup高效参数同步

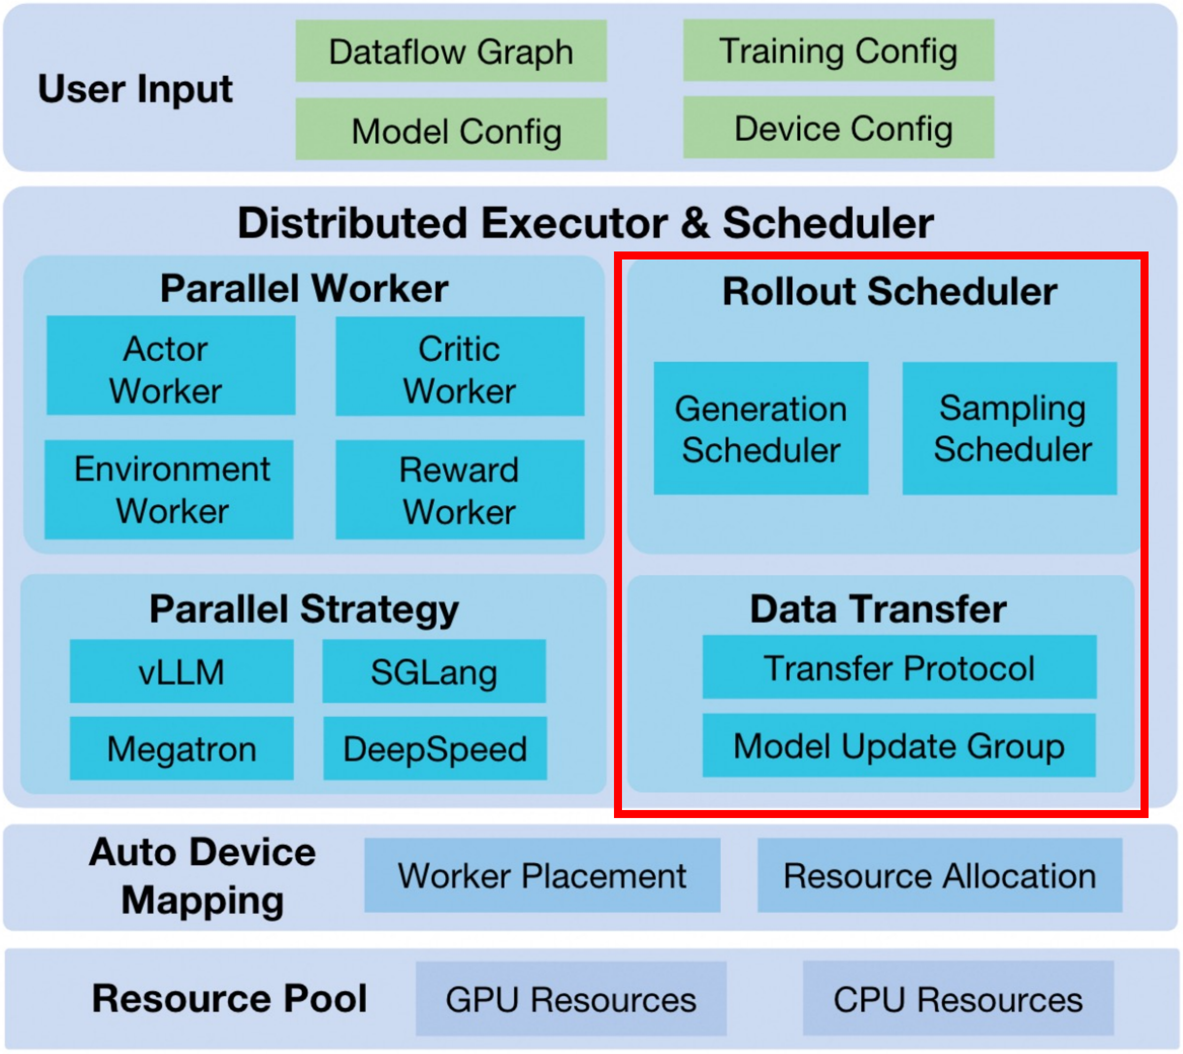

(a) Architecture

框架架构：面向分布式与高性能的LLM执行体系

模块化与可扩展的分布式架构

灵活资源管理：AutoDeviceMapping

➢ 灵活的资源管理，支持用户自定义设备映射，支持共置(colocated)和分离部署(disaggregated)

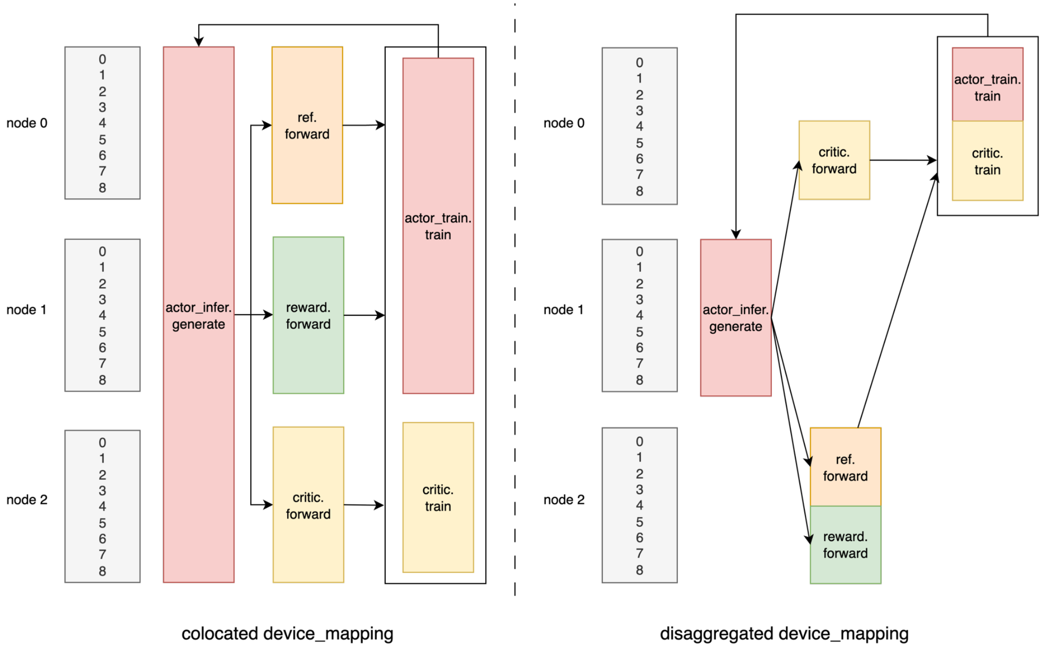

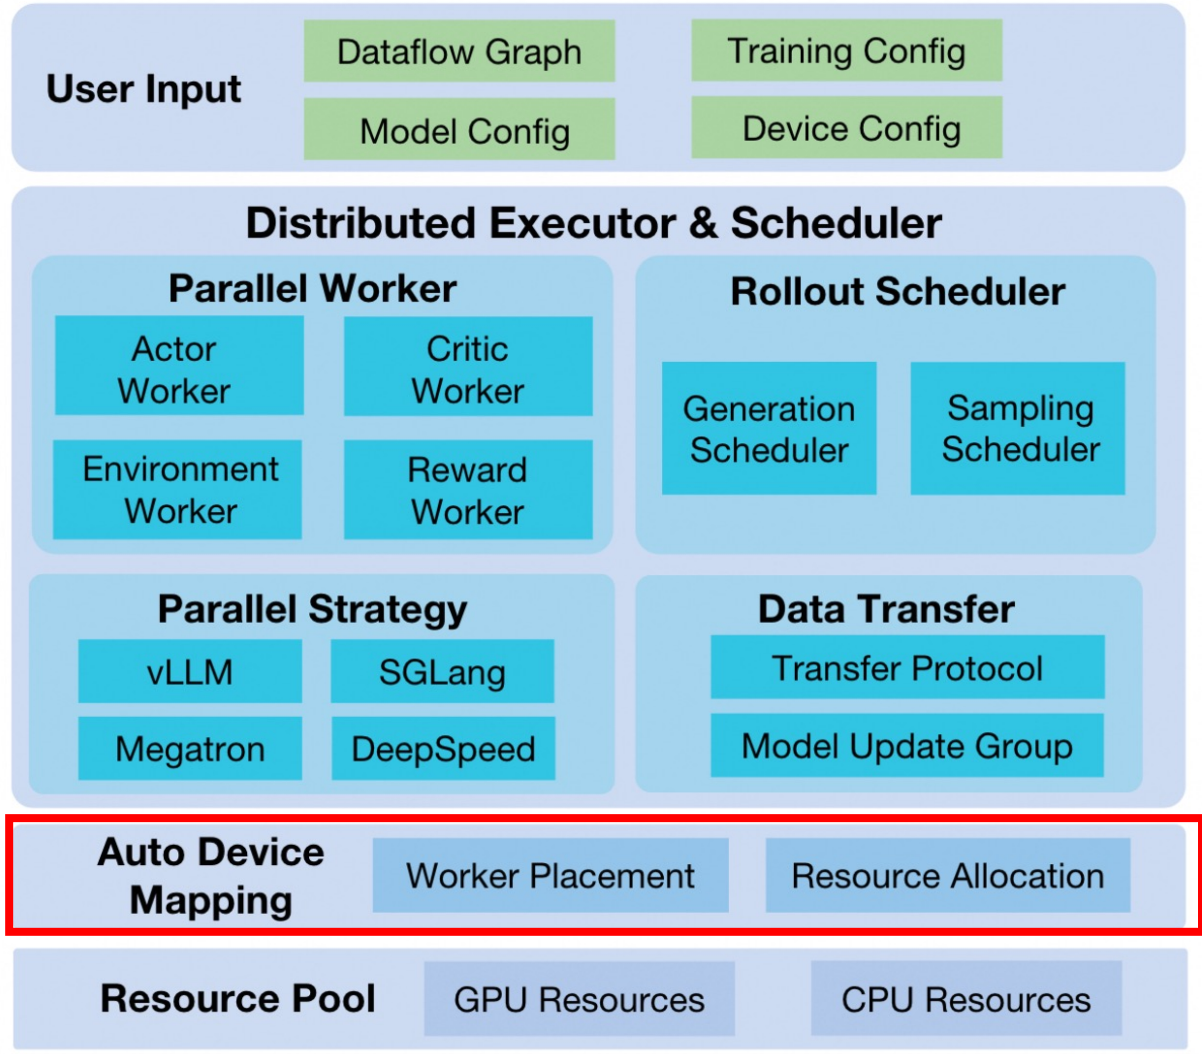

(a) Architecture

RLVR 多任务训练与异步奖励计算

多任务联合训练

- ROLL内置丰富的RL任务支持，涵盖数学、代码、通用推理、开放式问答、指令遵循等
- 一个训练循环即可多领域联合优化，采样率与数据权重可灵活动态调整

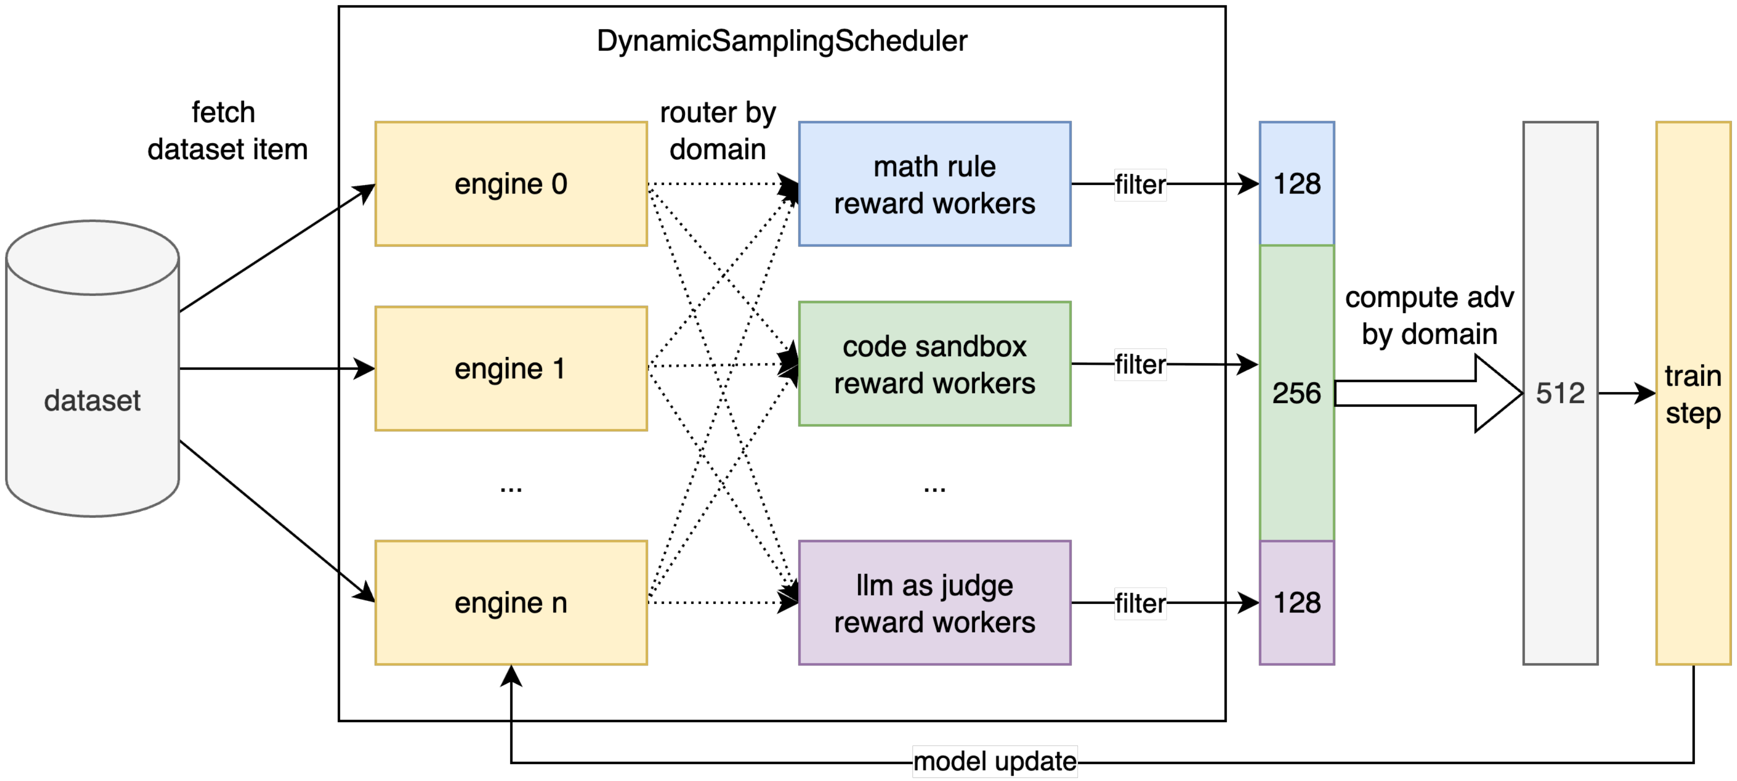

RLVR 多任务训练与异步奖励计算

多任务联合训练

1. 数据抽取 (Dataset): 从多领域数据集中fetch prompt
2. response生成：actor_infer engine并行生成response
3. Reward计算与过滤：根据Prompt所属domain，路由到Reward Worker，并动态过滤
4. Adv计算：按domain计算adv
5. 模型训练与更新

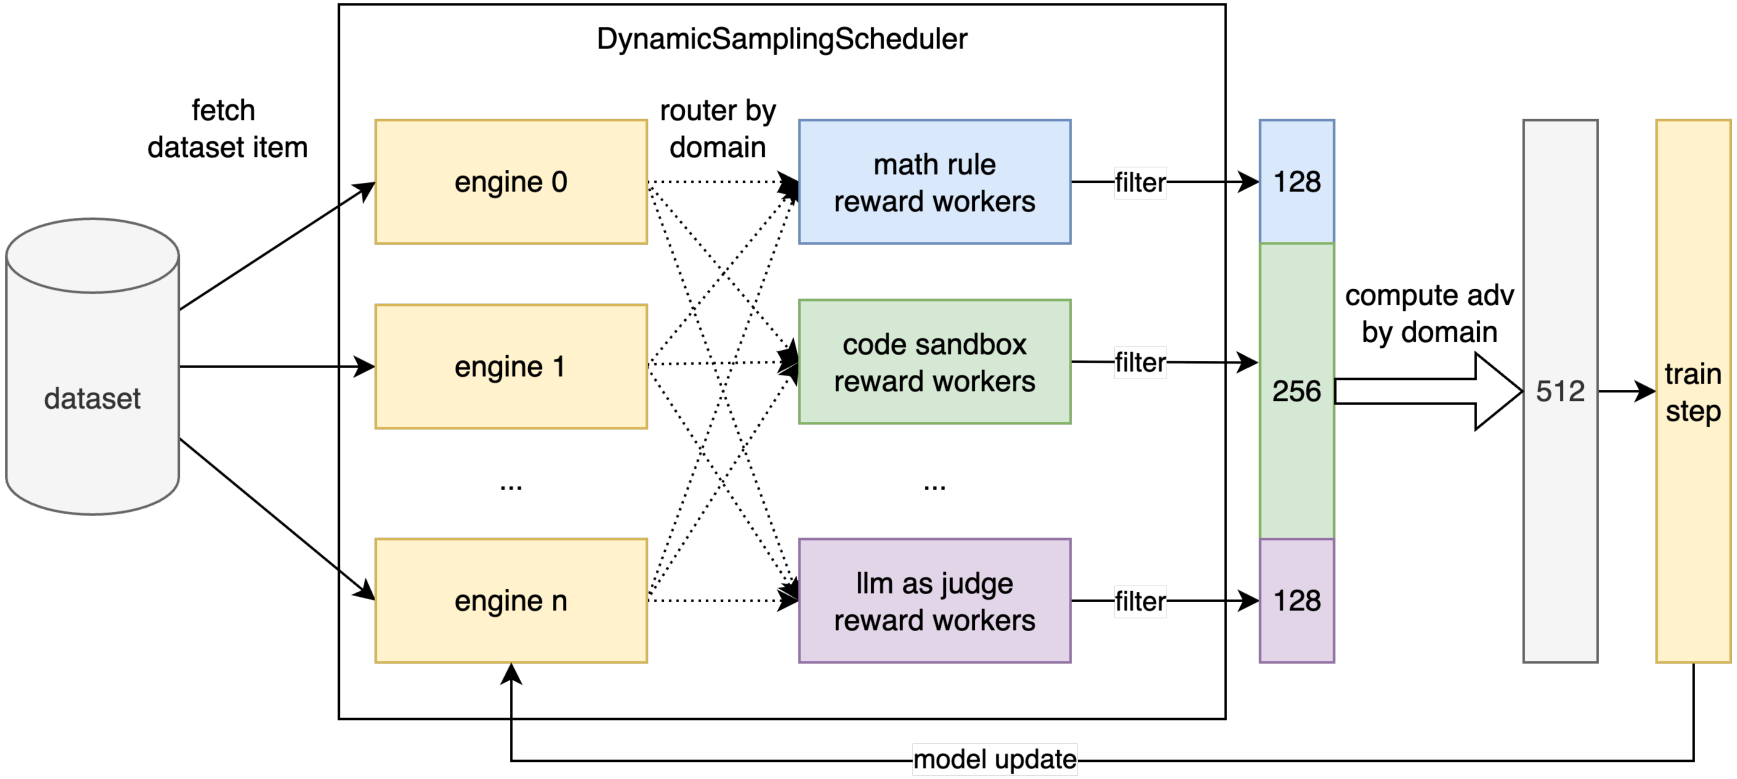

RLVR 多任务训练与异步奖励计算

异步奖励计算 与 动态过滤

- 传统的batch rollout
  - 生成、奖励计算、过滤 串行进行
  - 大量时间等待，导致GPU资源闲置
- ROLL: 样本级async rollout，压榨GPU效率
  - DynamicSamplingScheduler管理Prompt生成，一旦生成完毕，立即调用对应reward Worker异步计算reward。(对应图中 generate 和 compute_rewards 的重叠与连续)

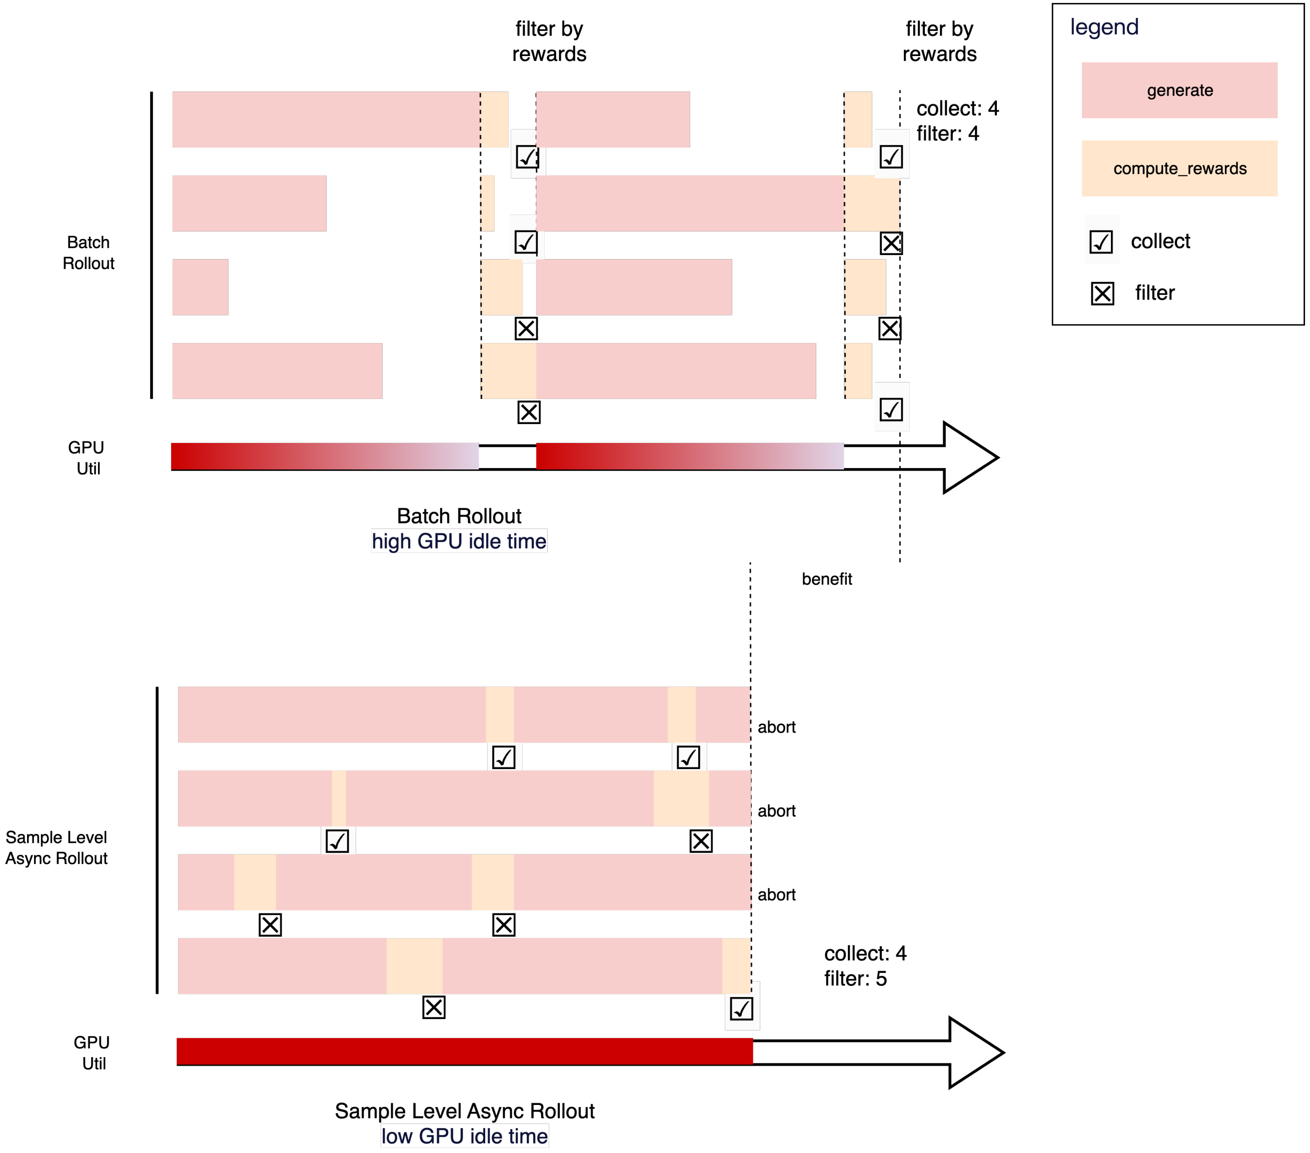

RLVR 多任务训练与异步奖励计算

多任务联合训练——实践

➢ 灵活的reward配置与路由

- YAML配置： 通过rewards定义各领域专属Reward Worker
- 动态实例化： worker_cls自动创建
- 自动数据路由： 根据数据tag（或domain），路由Reward Worker计算

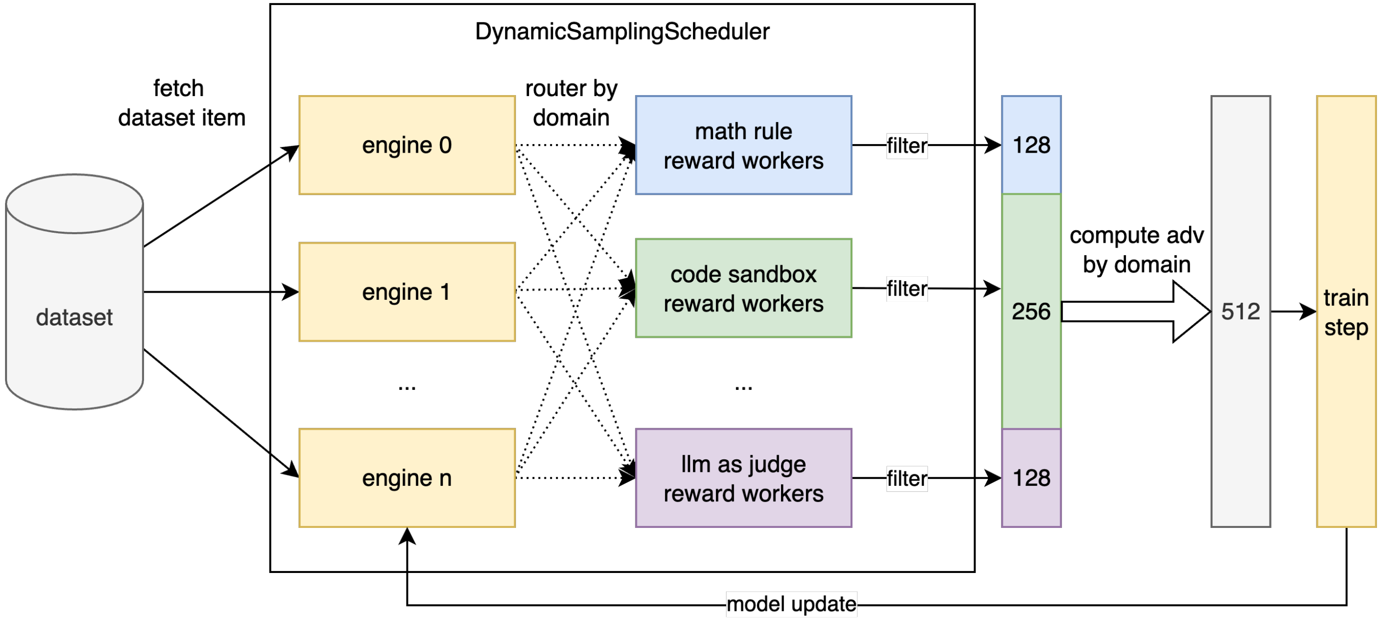


```yaml
rewards:
  math_rule:
    worker_cls: roll.pipeline.rlvr.rewards.math_rule_reward_worker.MathRuleRewardWorker
    tag_included: [deepmath_103k, aime]
  code_sandbox:
    worker_cls: roll.pipeline.rlvr.rewards.code_sandbox_reward_worker.CodeSandboxRewardWorker
    tag_included: [KodCode]
  llm_judge:
    worker_cls: roll.pipeline.rlvr.rewards.llm_judge_reward_worker.LLMJudgeRewardWorker
    tag_included: [RLVR]
```

RLVR 多任务训练与异步奖励计算

多任务联合训练——实践

- 动态采样过滤（DynamicSamplingScheduler）
  - 域独立调度： 为每个域配备专属的 DynamicSamplingScheduler
  - 样本级生成与奖励计算： scheduler均衡向 actor_infer发送prompt请求，并对应domain Reward Worker计算reward
  - 动态过滤：自定义函数对response进行动态过滤

```python
def query_filter_fn(data_list: List[DataProto], config: RLVRConfig) -> bool:  1 usage  xiongshaopan.xsp +1
    """
    各domain的过滤规则可以自定义
    """
    response_level_rewards = [data.batch["response_level_rewards"] for data in data_list]
    if len(response_level_rewards) == 1:
        return True
    rewards = torch.cat(response_level_rewards, dim=0)

    domain = data_list[0].non_tensor_batch["domain"][0]
    query_filter_config = config.rewards[domain].query_filter_config

    if query_filter_config.type == "no_filter":
        return True
    elif query_filter_config.type == "mean_filter":
        threshold_up = query_filter_config.filter_args.get("threshold_up", math.inf)
        threshold_down = query_filter_config.filter_args.get("threshold_down", -1)
        if torch.mean(rewards) <= threshold_down or torch.mean(rewards) >= threshold_up:
            return False
    elif query_filter_config.type == "std_filter":
        std_threshold = query_filter_config.filter_args.get("std_threshold", -1)
        if torch.std(rewards) <= std_threshold:
            return False
    return True
```

RLVR 多任务训练与异步奖励计算

多任务联合训练——实践

- 灵活的domain batch size分布控制
  - 保持全局rollout_batch_size不变
  - 基于domain_interleave_probs参数，灵活分配每个域的Batch Size比例
    - 示例：数学40%，代码30%，LLM Judge 10%...
  - [进阶玩法]根据任务训练情况动态调整，提升训练效果

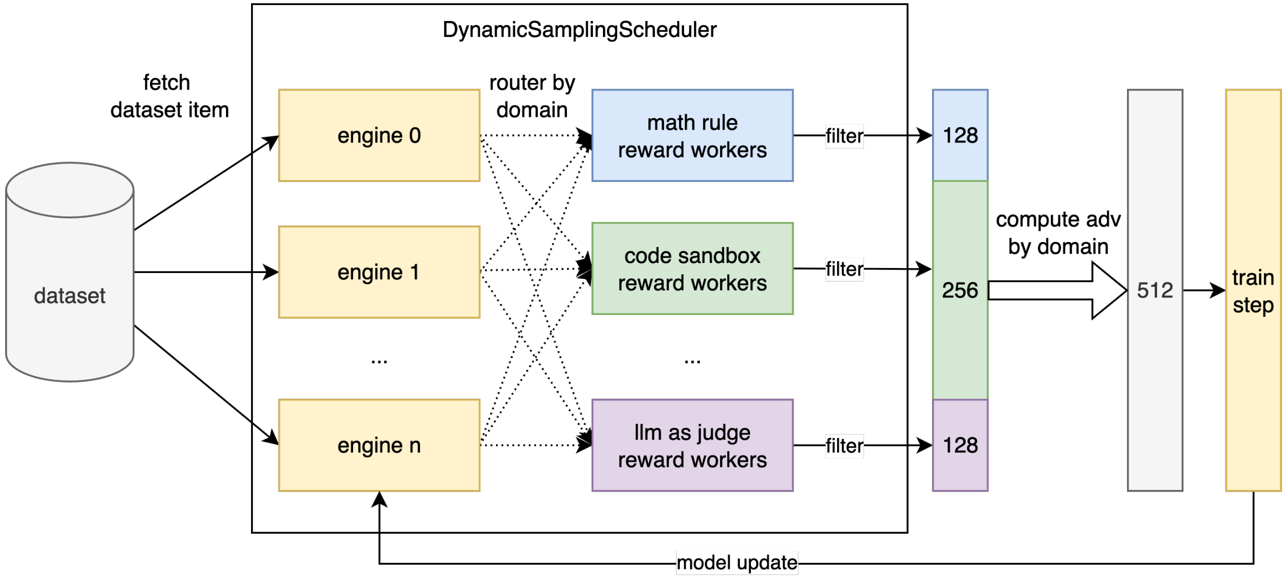


```yaml
domain_interleave_probs:
  math_rule: 0.4
  code_sandbox: 0.3
  llm_judge: 0.1
  crossthinkqa: 0.1
  ifeval: 0.1
```

```python
scheduler_refs = {}
for domain, scheduler in self.generate_schedulers.items():
    scheduler_refs[domain] = scheduler.get_batch.remote(data=batch,
                                                        batch_size=self.domain_batch_size[domain])
ray.get(list(scheduler_refs.values()))
```

Agentic 异步并行rollout与异步训练

异步并行rollout

- ➢ Batch Rollout
  - 执行模式: 同步、批次化执行
  - 核心特点:
    - ☐ barrier: 各阶段强制等待最慢的环境完成
    - ☐ 资源利用率低: 导致大量 GPU空闲时间
    - ☐ 性能瓶颈: 整体速度受最慢环境限制
- ➢ ROLL: Async Parallel Rollout
  - 执行模式: 解耦、基于env粒度的并行执行
  - 核心特点:
    - ☐ 无barrier: 各环境独立推进，不互相等待
    - ☐ 高资源利用率: GPU持续工作
    - ☐ 整体速度更快: 减少总Rollout时间
    - ☐ 灵活性高: 适应异构环境和动态控制

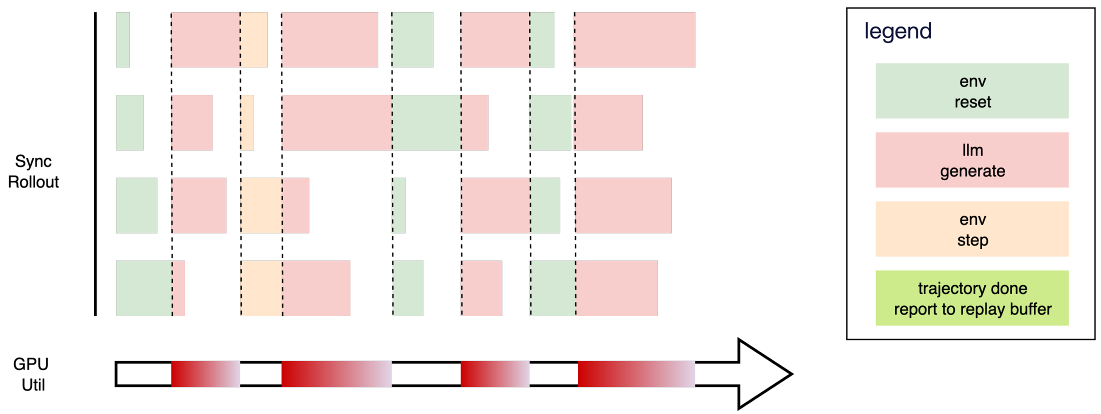

Sync Rollout:
Barriers at each stage, leading to high GPU idle time

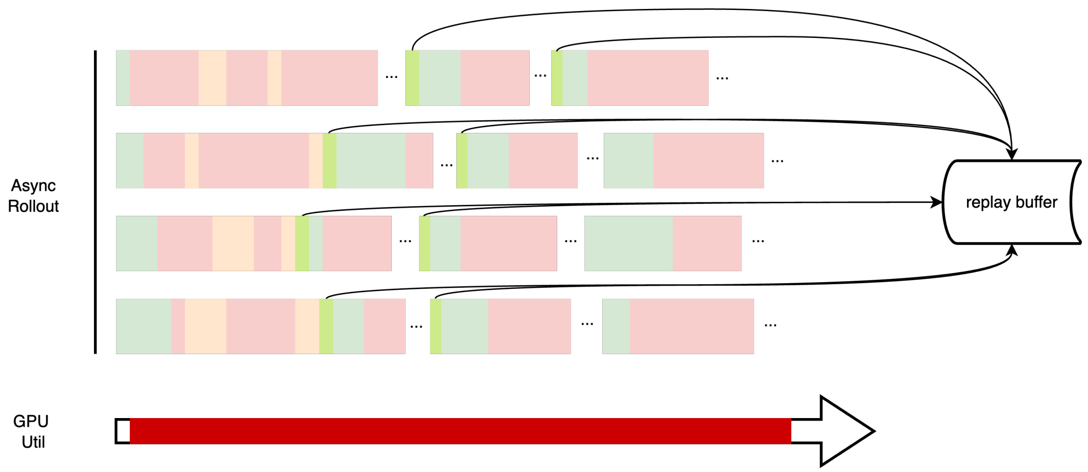

Async Rollout:
Parallel rollouts are executed per env, ensuring high GPU utilization

Agentic 异步并行rollout与异步训练

异步并行rollout

- 多轮交互EnvManager
  - 核心: 异步并行Rollout的基石
  - 职责: 管理单个环境 (BaseEnv) 的rollout
  - 特性: 自包含，支持本地调试与并行部署
- 核心功能与运行机制
  - run_rollout_loop: 执行完整Rollout（环境交互、LLM决策）直至采样结束
  - LLM决策: 通过LLMProxy生成action
  - 环境步进: 应用动作，收集环境反馈
  - 多EnvManager并行执行，发送完整轨迹至队列 (GroupQueueManager)

```python
class TrajEnvManager(BaseEnvManager):

    def run_rollout_loop(self, data: DataProto):
        self.episode_id = 0
        self.group_seed = data.meta_info['seed'] + self.env_config['group_seed']
        rollout_cache: RolloutCache = self.reset()
        start_step = self.current_step

        while self.running:

            lm_output: DataProto = self.make_decision(rollout_cache)
            stop_reason = lm_output.meta_info.pop("stop_reason")

            if stop_reason == GenerateStopReason.FINISH:
                rollout_cache: RolloutCache = self.step(lm_output)

            if self.running and (rollout_cache.terminated or stop_reason == GenerateStopReason.MAX_LENGTH):

                rollout: DataProto = self.formulate_rollouts(rollout_cache)

                traj_group_id = f"{self.env_config['group_id']}_{self.episode_id}_{self.group_seed}"
                rollout.non_tensor_batch["traj_group_id"] = np.array([traj_group_id], dtype=object)
                ray.get(self.output_queue.put.remote(self.env_config['group_id'], self.episode_id, start_step, rollout))

                self.rollout_cache = None
                if not self.running or self.episode_id >= self.worker_config.max_traj_per_env:
                    self.logger.debug(
                        f"env_id: {self.env_config['env_id']} max_traj_per_env {self.worker_config.max_traj_per_env} reached, stopping rollout loop")
                    break

                rollout_cache = self.reset()
```

Agentic 异步并行rollout与异步训练

异步并行rollout

- EnvManager: 多轮交互的本地调试
- 痛点：多轮交互调试之殇
  - **高昂代价:** 调试LLM与环境多轮交互，需启动分布式，耗时且资源巨大
  - **效率低下:** 新环境、Prompt格式调试迭代周期长，成本高
  - **复杂难解:** 分布式环境下多轮交互问题排查困难

ROLL
like a Reinforcement Learning Algorithm Developer

Agentic 异步并行rollout与异步训练

异步并行rollout

- EnvManager: 多轮交互的本地调试
- 解决方案：EnvManager的“自包含”设计
  - 核心: EnvManager 独立封装RL采样逻辑 (Env、LLM交互、数据收集)
  - 关键机制：
    - LLMProxy：实现可灵活切换，训练使用policy model，调试使用random/openai_chat_api
    - 开发者可在本地直接实例化EnvManager，轻松运行与调试轨迹采样过程

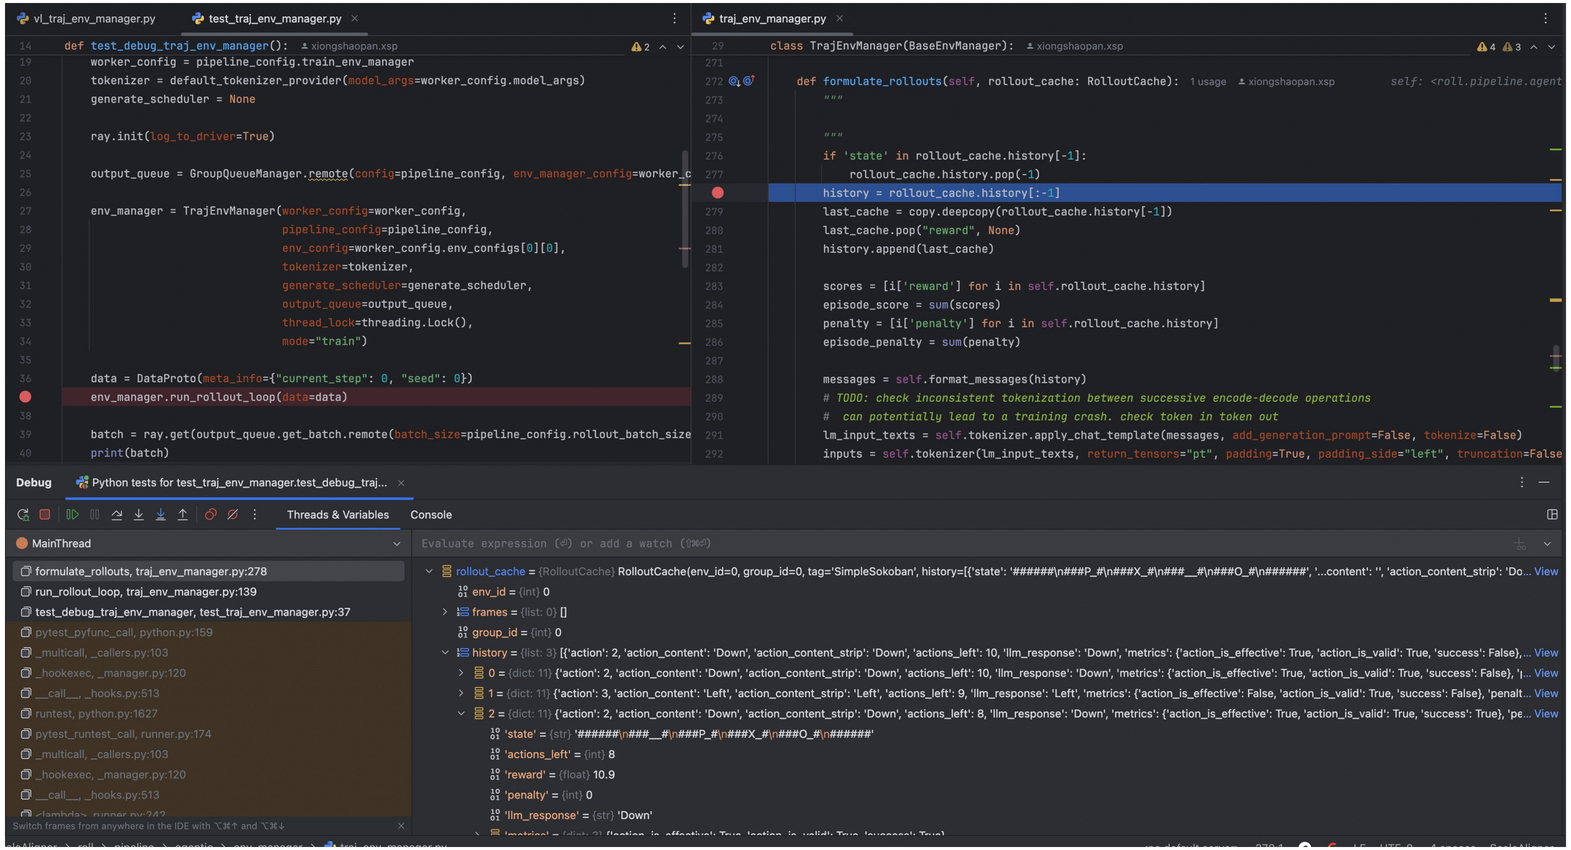

Agentic 异步并行rollout与异步训练

异步训练

- Sync training
  - 多轮rollout、训练串行进行
  - 生成长尾问题严重，GPU空闲，利用率低
- ROLL: Async training
  - rollout/训练解耦，扩展性高
  - 消除等待，GPU持续工作

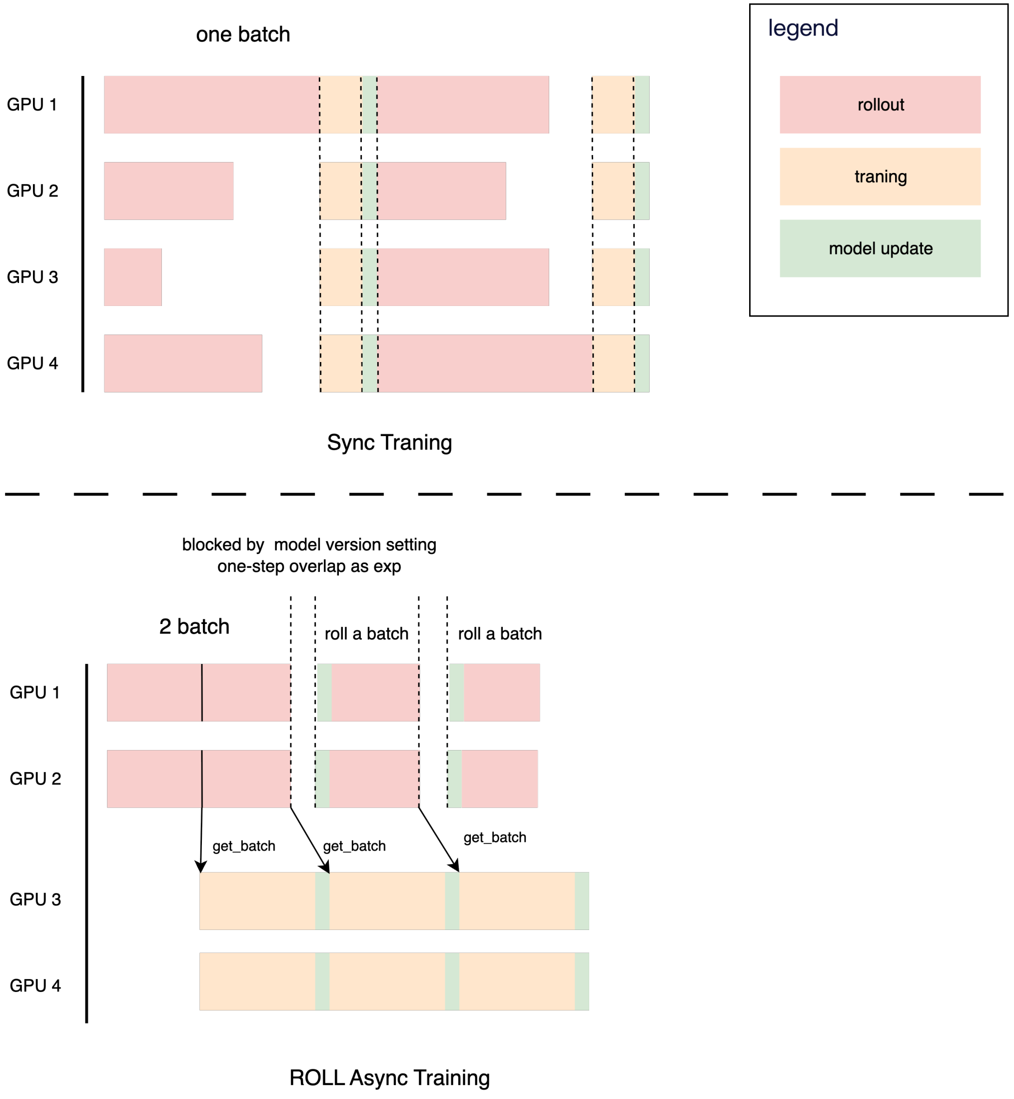

Agentic 异步并行rollout与异步训练

ROLL: Async training 实现

- ➢ 异步并行rollout (EnvManager)
  - EnvManager.run_rollout_loop() 并行运行
  - 异步生成agent与env交互轨迹
- ➢ 数据缓冲与解耦 (GroupQueue)
  - 各EnvManager 将轨迹推送到 GroupQueue
- ➢ 异步训练循环 (Training Loop)
  - suspend(): 停止rollout，准备模型更新
  - model_update()): actor_train –> actor_infer
  - resume(): 新模型恢复rollout
  - get_batch(): block式从GroupQueue取数据
  - train_step(): 模型训练

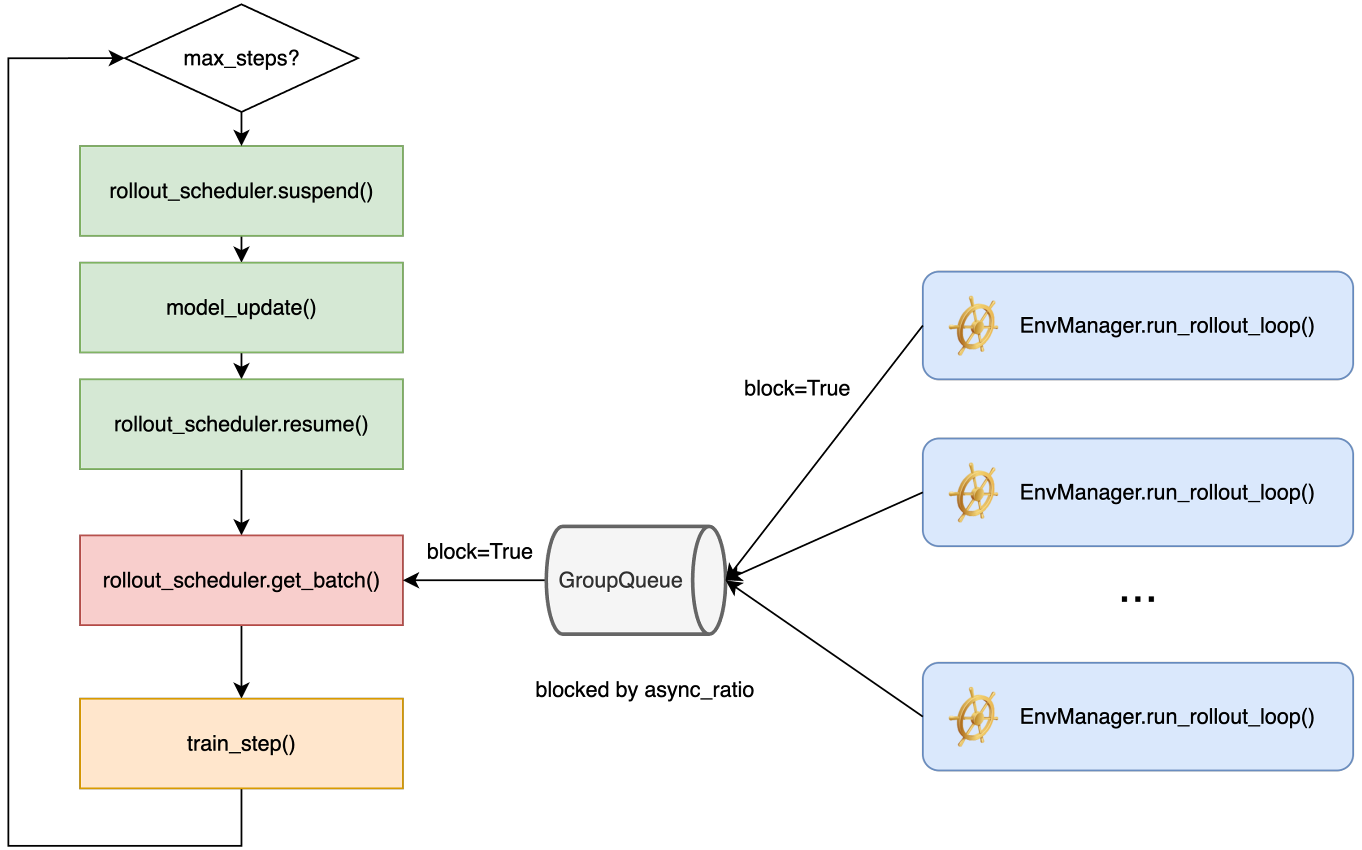

Part 3：ROLL实践篇

ROLL
like a Reinforcement Learning Algorithm Developer

易用性与灵活性：满足你的个性化需求

➢ 自定义Pipeline:

- 算法同学可直接DIY RL计算流，编排Worker的计算流程
- 内置rlvr_pipeline和agentic_pipeline作为标准模板
- 专注于业务逻辑，无需关心底层分布式细节

pipeline demo

```python
class PipelineDemo:
    def __init__(self):
        self.actor_train: Any = Cluster(role_type=TrainRole, resource_pool=4, config=dict(dp=2,
        self.actor_infer: Any = Cluster(role_type=TrainRole, resource_pool=4, config=dict(dp=2,
        self.reference: Any = Cluster(role_type=InferRole, resource_pool=2, config=dict(dp=2, tp
        self.reward: Any = Cluster(role_type=InferRole, resource_pool=4, config=dict(dp=2, tp=2)
        self.critic: Any = Cluster(role_type=InferRole, resource_pool=4, config=dict(dp=2, tp=1)

        self.actor_train.initialize()
        self.actor_infer.initialize()
        self.reference.initialize()
        self.reward.initialize()
        self.critic.initialize()

        self.model_update_group = ModelUpdateGroup(src_cluster=self.actor_train, tgt_cluster=sel

        num_samples = 64
        seq_length = 8
        batch_size = 8
        dataset = CustomDataset(num_samples=num_samples, seq_length=seq_length)
        self.data_loader = DataLoader(dataset, batch_size=batch_size, shuffle=True)

    def run(self):
        step = 0
        for batch_data in self.data_loader:
            batch = DataProto.covert(batch=batch_data)
            batch = self.actor_infer.generate(batch=batch)
            batch = self.reference.compute_logprobs(batch=batch)
            batch = self.reward.forward(batch=batch)
            batch = self.critic.forward(batch=batch)
            batch = compute_advantage(batch)
            self.actor_train.train_step(batch=batch)
            self.critic.train_step(batch=batch)
            self.model_update_group.model_update()
            self.do_checkpoint(step=step)
            step += 1
```

易用性与灵活性：满足你的个性化需求

- 自定义Reward
  - 内置多种常用奖励计算方式（数学规则、代码沙箱、LLM as Judge等）
  - 提供清晰接口，轻松扩展自定义奖励逻辑，满足特定业务需求

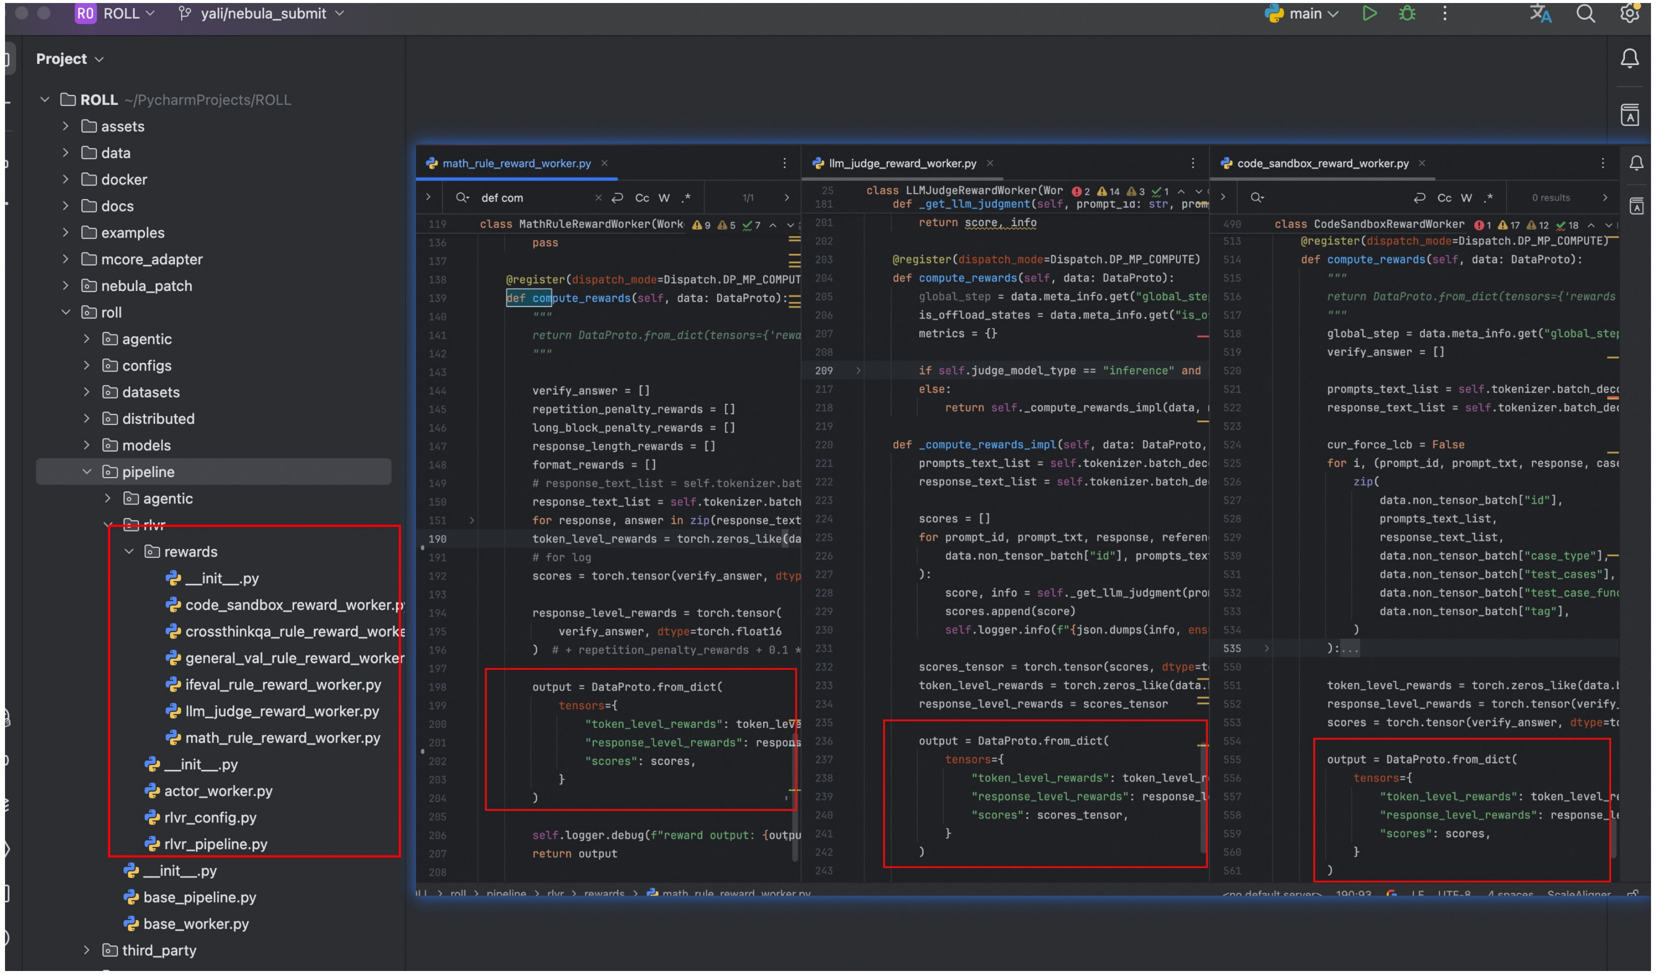

易用性与灵活性：满足你的个性化需求

- 自定义Environment与多轮交互
  - 提供Gym-like标准接口，快速构建和扩展自定义环境
  - 支持Ray Actor和线程级部署，灵活选择
  - 用户可控的RL Rollout Loop: 自由编写Agent与Env交互逻辑，包括多轮对话、工具调用等
  - 极致的开发效率：多轮交互可本地调试

```python
class TrajEnvManager(BaseEnvManager):  xiongshaopan.xsp *

    def run_rollout_loop(self, data: DataProto):  4 usages (2 dynamic)  xiongshaopan.xsp *
        self.episode_id = 0
        self.group_seed = data.meta_info['seed'] + self.env_config['group_seed']
        rollout_cache: RolloutCache = self.reset()
        start_step = self.current_step

        while self.running:

            lm_output: DataProto = self.make_decision(rollout_cache)
            stop_reason = lm_output.meta_info.pop("stop_reason")

            if stop_reason == GenerateStopReason.FINISH:
                rollout_cache: RolloutCache = self.step(lm_output)

            if self.running and (rollout_cache.terminated or stop_reason == GenerateStopReason.MAX_LENGTH):

                rollout: DataProto = self.formulate_rollouts(rollout_cache)

                traj_group_id = f"{self.env_config['group_id']}_{self.episode_id}_{self.group_seed}"
                rollout.non_tensor_batch["traj_group_id"] = np.array( object: [traj_group_id], dtype=object)
                ray.get(self.output_queue.put.remote(self.env_config['group_id'], self.episode_id, start_step, rollout))

                self.rollout_cache = None
                if not self.running or self.episode_id >= self.worker_config.max_traj_per_env:
                    self.logger.debug(
                        f"env_id: {self.env_config['env_id']} max_traj_per_env {self.worker_config.max_traj_per_env} reached, stopping rollout loop")
                    break

                rollout_cache = self.reset()
```

base.py

gym like api

```python
import ...

class BaseEnv(ABC):  2 usages  xiongshaopan.xsp
    """..."""

    def __init__(self):...

    @abstractmethod  xiongshaopan.xsp
    def reset(self, seed=None, **kwargs) -> Any:
        """..."""
        pass

    @abstractmethod  xiongshaopan.xsp
    def step(self, action) -> Tuple[Any, float, bool, Dict]:...

    # below are optional methods

    def render(self, mode: str = "text") -> Any:...

    def compute_reward(self, action, **kwargs) -> float:  xiongs
        """Compute reward for the action."""
        pass

    def close(self):...


class BaseDiscreteActionEnv(BaseEnv, ABC):  9 usages  xiongshaopan.
    """
    Abstract base class for environments with discrete action sp
    This class provides common functionality for environments li
    """

    @abstractmethod  xiongshaopan.xsp
```

environment_worker.py   env.py

```python
class SokobanEnv(BaseDiscreteActionEnv, GymSokobanEnv):  6 usages  xiongshaopan.xsp
    def __init__(self, config=None, **kwargs):  xiongshaopan.xsp
        self.config = config or SokobanEnvConfig()
        self.GRID_LOOKUP = self.config.grid_lookup
        self.ACTION_LOOKUP = self.config.action_lookup
        self.search_depth = self.config.search_depth
        self.ACTION_SPACE = gym.spaces.discrete.Discrete( n: 4, start=1)
        self.render_mode = self.config.render_mode

        BaseDiscreteActionEnv.__init__(self)
        GymSokobanEnv.__init__(
            self,
            dim_room=self.config.dim_room,
            max_steps=self.config.max_steps,
            num_boxes=self.config.num_boxes,
            **kwargs,
        )

    def reset(self, seed=None):...

    def step(self, action: int):...

    def render(self, mode=None):...

    def get_all_actions(self):  xiongshaopan.xsp
        return list([k for k in self.ACTION_LOOKUP.keys()])

    def close(self):  xiongshaopan.xsp
        self.render_cache = None
        super(SokobanEnv, self).close()
```

代码实操

运行环境

- H20
- Python3.10
- Torch 2.6.0
- 镜像：roll-registry.cn-hangzhou.cr.aliyuncs.com/roll/pytorch:nvcr-24.05-py3-torch260-vllm084

用户配置 .yaml

➢ Model Scope 模型下载配置

rlvr_qwen2.5_7B_megatron_vllm_8gpus_model_scope.yaml

```yaml
#     - baseline


model_download_type: MODELSCOPE

  llm_judge:
    # NOTE: llm as judge 也需要gpu, 不能和actor infer共享gpu
    worker_cls: roll.pipeline.rlvr.rewards.llm_judge_reward_worker.LLMJudgeRewardWorker
    judge_prompt: Qwen2.5-7B-Instruct-RLVR-prompt
    judge_model_type: inference
    tag_included: [RLVR]
    model_args:
      model_name_or_path: AI-ModelScope/Qwen2.5-7B-Instruct-RLVR
      disable_gradient_checkpointing: true
      dtype: bf16
      model_type: trl
```

➢ Swanlab 实验配置

```yaml
track_with: swanlab
tracker_kwargs:
  login_kwargs:
    api_key: your_api_key
  project: roll-rlvr
  logdir: debug
  experiment_name: roll-rlvr-examples
  tags:
    - roll
    - rlvr
    - debug
```

代码实操

任务启动：sh run_pipeline.sh

➢ sh run_rlvr_pipeline.sh 一键启动

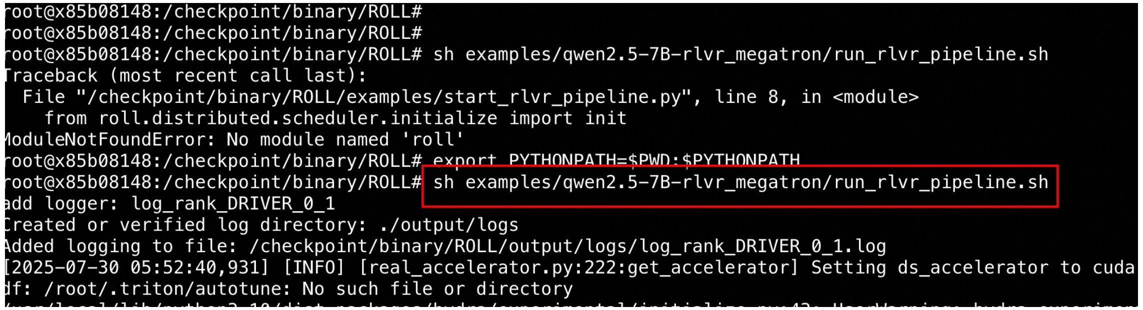

➢ model scope 模型下载

➢ SwanLab 初始化

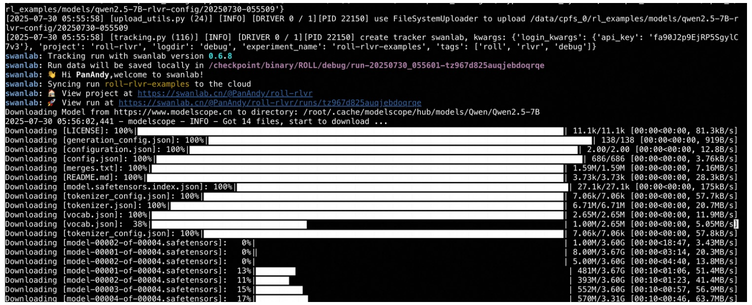

➢ SwanLab 实验监控

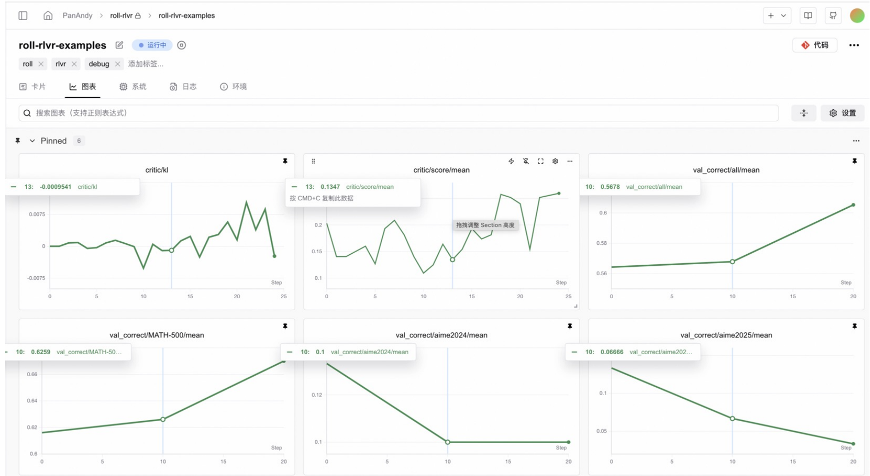

代码实操

多轮交互EnvManager本地调试

本地依赖安装(mac)：

test_traj_env_manager.py

```
"""
usage:

conda create -n python310_torch260_em  python=3.10

pip3 install torch torchvision torchaudio py-cpuinfo
pip install -r requirements_em_local_debug.txt

python tests/agentic/env_manager/test_traj_env_manager.py
"""
import threading
```

IDE debug/单步调试：

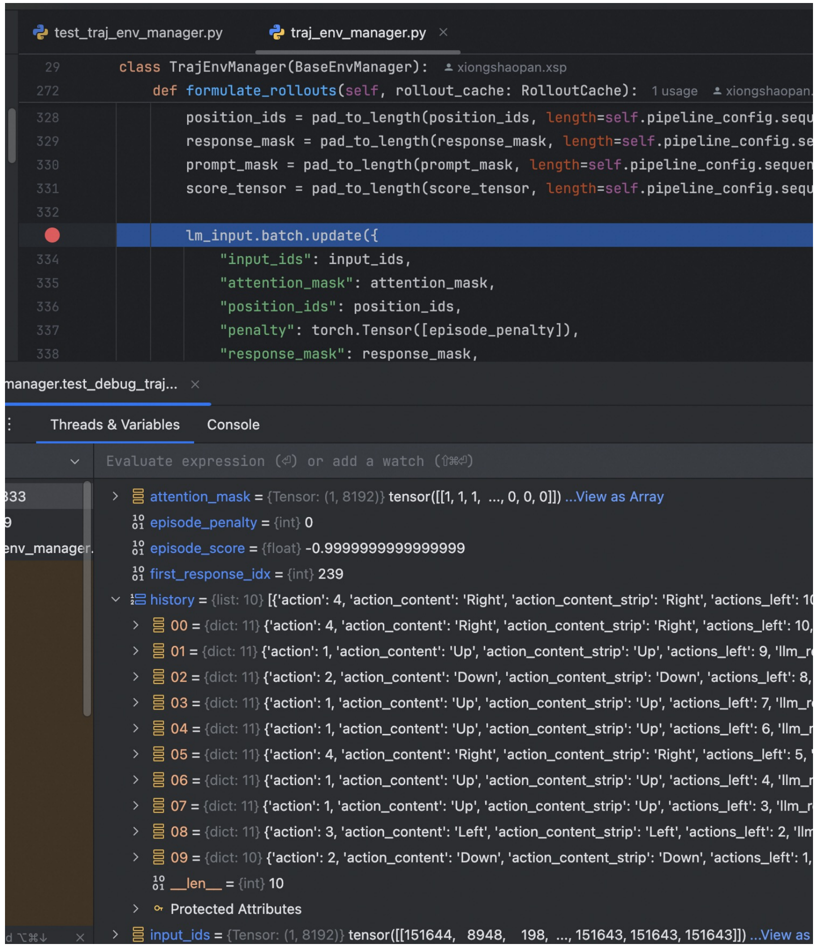

ROLL！！！

- 行动起来： 加入ROLL社区，一起探索LLM RL的未来!
    - GitHub: https://github.com/alibaba/ROLL
    - Paper: https://arxiv.org/abs/2506.06122

扫码进ROLL项目交流群

非常感谢